



Estimasi Curah Hujan Berbasis *Convolutional Neural Network - Long Short Term Memory* (CNN-LSTM) dengan *Input* Video Kamera Pengawas

Erwan Herlandy (2106706741)

Pembimbing: Adhi Harmoko Saputro, Ph.D.

Penguji 1: Dr. Arief Sudarmaji, M.T.

Penguji 2: Surya Darma, S.Si., M.Si., CertDA

Daftar Isi

1. Pendahuluan

- Latar Belakang
- Rumusan Masalah dan Batasan Masalah
- Tujuan Penelitian dan Manfaat Penelitian

2. Kajian Pustaka

- Instrumen Pengukuran Curah Hujan
- Teknik Preprocessing Citra
- Isu Performa Deep *Learning* Model

3. Metodologi

- Arsitektur Sistem
- Konfigurasi Akuisisi Data
- Preprocessing Citra
- Preprocessing Data Curah Hujan
- Rancangan Arsitektur Model CNN-LSTM dan Metode Evaluasi

4. Hasil dan Pembahasan

- Hasil Citra Kamera Pengawas
- Pemrosesan Data Automatic Rain Gauge
- Distribusi Curah Hujan pada Dataset All-day
- Hasil Dataset *Automatic Rain Gauge*
- Hasil Konfigurasi Terbaik

5. Kesimpulan

6. Referensi

Pendahuluan

Estimasi Curah Hujan Berbasis Convolutional Neural Network - Long Short Term Memory (CNN-LSTM) dengan Input Video Kamera Pengawas

Pendahuluan

Latar Belakang Penelitian (1/3)

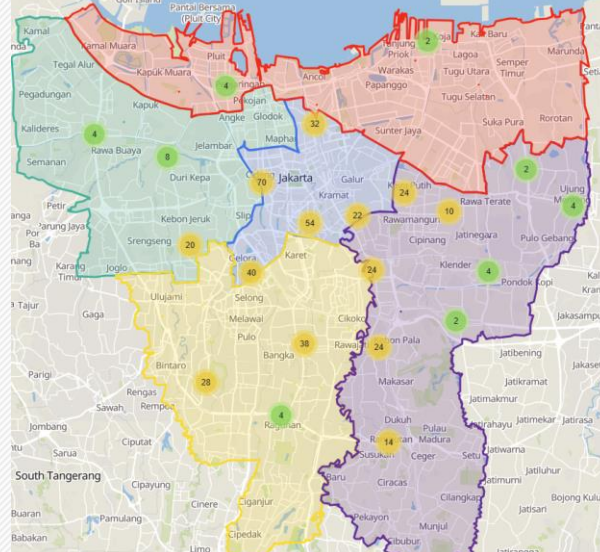


Penelitian mengenai **estimasi curah hujan** menggunakan **input kamera pengawas** pada beberapa tahun terakhir **telah banyak dilakukan**. (Haurum et al., 2019)

Keunggulan Kamera Pengawas


- + Tersebar luas
- + Tidak perlu instalasi baru
- + Menangkap fitur visual hujan

Persebaran Kamera Pengawas ATCS (Area Traffic Control System) di Jakarta



Jakarta memiliki 250+ Kamera ATCS

Sumber: <https://atcs-jakarta.com/Maps>



Studi menunjukkan bahwa pendekatan visual berbasis deep learning memiliki beberapa keunggulan:

- Studi estimasi hujan dari **awal hingga terbaru** menunjukkan peningkatan akurasi yang signifikan
- **Penyediaan data secara real-time** yang dapat mendukung pengambilan keputusan dalam **manajemen smart city**.

(Wang et al., 2025; Allamano et al., 2015)

Pendahuluan

Latar Belakang Penelitian (2/3)



Dalam penerapannya kamera pengawas menghadapi **berbagai tantangan** teknis, sehingga belum dapat digunakan secara langsung di **berbagai kondisi waktu dan lingkungan**



Tantangan Penggunaan Kamera dalam Estimasi Hujan



Gangguan objek bergerak
Kendaraan, pejalan kaki, pohon bergerak menimbulkan noise visual sehingga menurunkan performa (Qin et al., 2025; Haurum et al., 2019)




Variasi pencahayaan dan kondisi malam hari
Perbedaan **intensitas cahaya** antara **pagi, siang, sore, dan malam** menyebabkan visual hujan tidak konsisten; performa model menurun di kondisi low-light (Wang et al., 2025; Fiallos-Salguero et al., 2025)



Overfitting terhadap latar tunggal
Studi seperti *Rajabi (2023)* hanya menggunakan **satu latar siang**, menyebabkan model tidak general (Rajabi et al., 2023)

Pendahuluan

Latar Belakang Penelitian (3/3)



Pendekatan **citra tunggal** tidak mampu menangkap **informasi temporal** seperti **intensitas hujan & pencahayaan antar waktu**. (Abid et al., 2022; Rahman et al., 2024)




Studi di bidang **gesture, lalu lintas, dan ekspresi wajah** telah berhasil menggunakan input video untuk **mempelajari dinamika visual secara sekuensial**. (Tran et al., 2015; Donahue et al., 2015).

Pendekatan video based ini menjadi relevan untuk estimasi curah hujan, karena memungkinkan model mempelajari pergerakan rintik hujan dan perubahan pencahayaan secara alami antar waktu.

Potensi Penyelesaian Masalah



Problem **variasi pencahayaan** dan **kondisi malam berpotensi** diselesaikan dengan **input video** karena dapat mengambil informasi dari perubahan pencahayaan antar waktu



Penggunaan **multiple ROI** berpotensi menyelesaikan masalah overfitting terhadap **latar belakang tunggal**

Pendahuluan

Rumusan Masalah & Tujuan Penelitian

Rumusan Masalah

- Bagaimana merancang arsitektur deep learning berbasis CNN-LSTM untuk estimasi curah hujan yang berkinerja tinggi pada berbagai kondisi waktu, seperti pagi, siang, sore, dan malam, dengan menggunakan data kamera pengawas.
- Seberapa besar pengaruh konfigurasi jumlah frame dan durasi video terhadap performa model estimasi curah hujan.
- Seberapa besar pengaruh perubahan kondisi waktu terhadap performa model estimasi curah hujan.

Tujuan Penelitian

- Membangun model deep learning berbasis CNN-LSTM untuk estimasi curah hujan yang robust terhadap perubahan kondisi waktu pagi, siang, sore, dan malam menggunakan video kamera pengawas.
- Mengevaluasi performa dan estimasi curah hujan terhadap variasi konfigurasi jumlah frame dan durasi input video.
- Mengevaluasi performa dan estimasi curah hujan sepanjang waktu.

Pendahuluan

Batasan Masalah & Manfaat Penelitian

Batasan Masalah

- Referensi curah hujan sensor Automatic Rain Gauge dengan resolusi 0,2 mm/menit
- Lokasi penelitian dibatasi pada tangkapan kamera pengawas di area Kantor Pusat BMKG, Kemayoran, Jakarta Pusat.
- Penelitian menggunakan jumlah kamera pengawas yang terbatas untuk memfokuskan analisis pada generalisasi temporal dengan data waktu dari pagi hingga malam.

Manfaat Penelitian

Penelitian yang dilakukan ini diharapkan dapat menghasilkan arsitektur model *deep learning* dengan kinerja yang tinggi yang tahan terhadap perubahan kondisi waktu dan intensitas cahaya, sehingga mampu memberikan data estimasi curah hujan. Selain itu, model *deep learning* yang dikembangkan dapat meningkatkan resolusi temporal curah hujan.

Kajian Pustaka

Estimasi Curah Hujan Berbasis Convolutional Neural Network - Long Short Term Memory (CNN-LSTM) dengan Input Video Kamera Pengawas

Kajian Pustaka

Instrumen Pengukuran Curah Hujan

Instrumen	Metode Pengukuran	Kelebihan	Kekurangan	Author (Year)
Ombrometer	Menampung air hujan untuk diukur menggunakan gelas ukur	Pemasangan yang mudah	Perhitungan masih dilakukan secara manual	Saloko et al. (2023)
Automatic Rain Gauge	Jumlah <i>tipping</i> permenit	Dapat mencatat secara otomatis	Resolusi yang terbatas	Lee et al. (2023)
Optical Rain Gauge	Kalkulasi kecepatan dan diameter hujan	Memiliki resolusi yang tinggi	Mudah terganggu oleh partikel selain hujan	Ro et al. (2024)
Remote Sensing	Mengukur radiasi mikro alami dari atmosfer dan permukaan bumi	Cakupannya lebih luas	Resolusi spasial yang rendah (5×5 km)	Behrangi et al. (2012)
Kamera Pengawas	Citra garis hujan yang diestimasi oleh model	Dapat menghasilkan data <i>spatio-temporal</i> yang tinggi	Performa model tidak berkinerja tinggi di berbagai kondisi waktu dan pencahayaan	X. Wang et al. (2023)

Kamera Pengawas merupakan sensor alternatif yang dapat menghasilkan data *spatio-temporal* yang tinggi dengan pemasangan yang relatif mudah, kekurangan dari kamera pengawas masih dapat diperbaiki melalui penelitian lanjutan

Kajian Pustaka

Jenis Input Pada Model Estimasi Hujan

Jenis Input	Tujuan	Kekurangan	Author (Year)
<i>Rain streak</i>	Memisahkan garis hujan dari <i>background</i>	Lambat, beresiko hilangnya informasi pada hujan-hujan ringan	Jiang et al. (2019)
<i>Grayscale</i>	Normalisasi antar waktu (siang/malam)	Kehilangan warna, info terbatas	F. Zheng et al. (2024)
RGB (<i>Native CCTV</i>)	Detail tinggi, cocok kondisi siang	Komputasi yang lebih berat, size dataset lebih besar	Rajabi et al. (2024)
Infrared Kamera	Meningkatkan visibilitas malam hari dengan menangkap pantulan cahaya inframerah	Gambar grayscale, kehilangan informasi warna, rentan noise cahaya IR	X. Wang et al. (2023)

Metode **grayscale** berperan sebagai teknik **preprocessing** yang efektif untuk menghadapi variasi waktu, karena mampu mengurangi pengaruh pencahayaan serta **menormalkan tampilan citra**. Meskipun kehilangan informasi warna, **grayscale** justru membantu model untuk lebih fokus pada tekstur dan intensitas hujan. Terutama pada malam hari, citra dari kamera akan berupa **grayscale**, sehingga normalisasi ini memungkinkan model untuk mendeteksi pola garis hujan secara konsisten.

Kajian Pustaka

Isu Perfoma Model Deep Learning

Jenis Input	Model	Unit Satuan Curah Hujan	Nilai Terbaik (MAPE)	Author (Year)
Video RGB (128×128 pixel)	Efnet+LSTM	mm/jam	3,18%	Rajabi et al. (2024)
Video RGB (540×380 pixel)	Resnet34+LSTM	mm/menit	15,18%	F. Zheng et al. (2024)
Gambar Grayscale (1920×1080 pixel)	1D CNN	mm/jam	21,66%	X. Wang et al. (2023)
Gambar RGB (1920×1080 pixel)	irCNN (Resnet34)	mm/jam	17,06%	F. Zheng et al. (2023)
Gambar RGB (1920×1080 pixel)	CNN	mm/jam	17,89%	Shalaby et al. (2024)
Video RGB (1280×720 pixel)	Resnet50+LSTM	mm/jam	13,62%	Qin et al. (2025)

Meskipun satuan curah hujan yang digunakan berbeda (mm/jam hingga mm/menit), model **hybrid CNN+LSTM** tetap memberikan performa terbaik dibandingkan model **CNN**. Hal ini menunjukkan kemampuannya menangani **target yang lebih kompleks dan detail**.

Kajian Pustaka

Isu Performa Deep *Learning* Model

Waktu	Model	NSE	Interpretasi	Author (Year)
Siang	ResNet34+LSTM	0,93	Model cukup akurat, pencahayaan optimal	F. Zheng et al. (2024)
Malam	ResNet34+LSTM	0,88	Sedikit menurun karena noise dan intensitas rendah	
Transisi	ResNet34+LSTM	0,84	Buruk dipengaruhi perubahan (subuh/senja)	
Siang dan Malam	Resnet50+LSTM	0,94	Noise yang tinggi menyebabkan kondisi akurasi buruk	Qin et al. (2025)
Siang	EfficientNet+LSTM	0,97	Akurat dengan pencahayaan yang optimal	Rajabi et al. (2024)

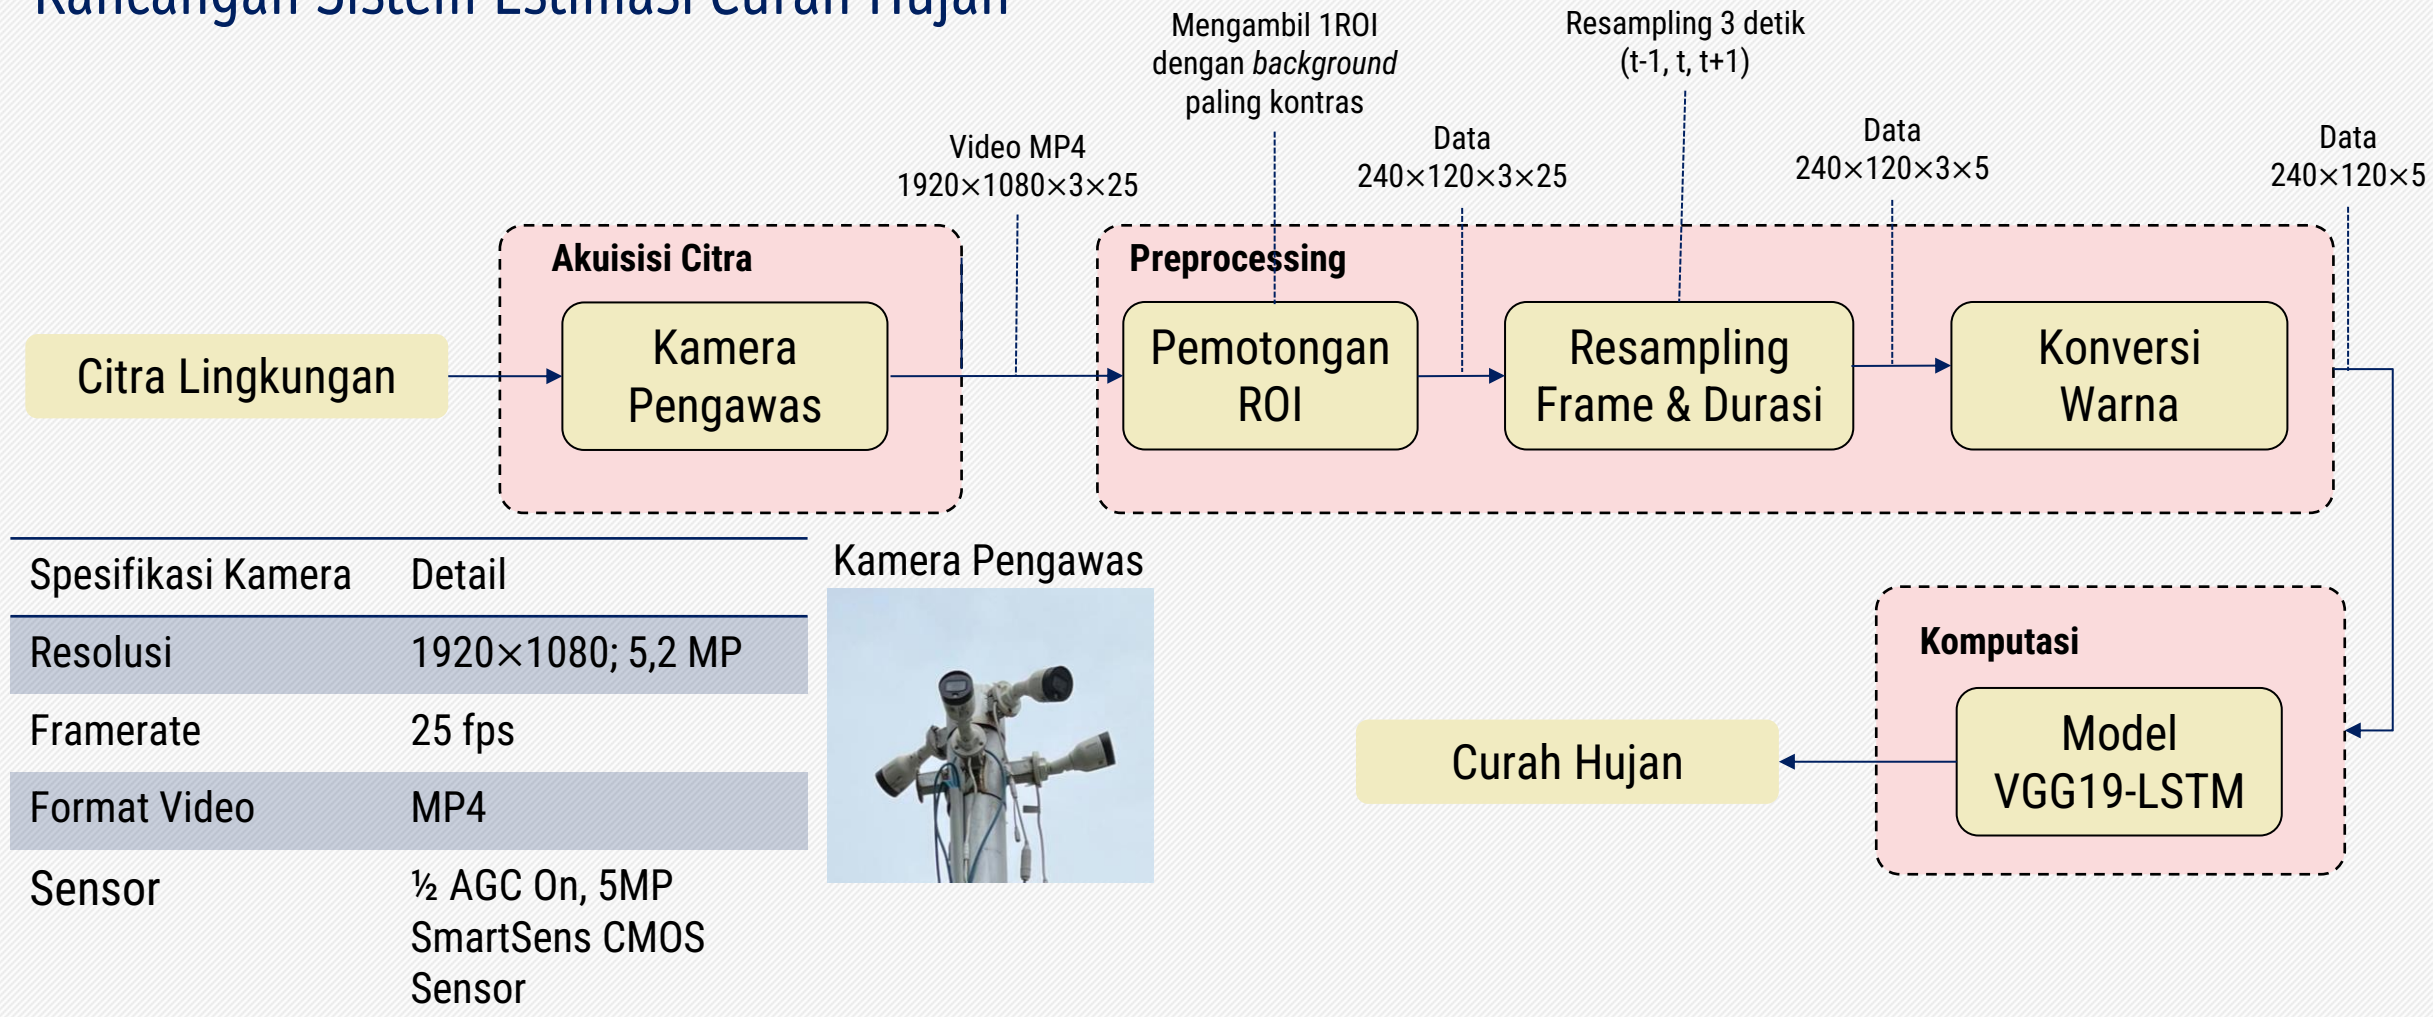
Model hybrid menunjukkan penurunan performa pada **malam dan transisi** waktu akibat noise dan perubahan pencahayaan. Sehingga diperlukan adanya *feature extractor* yang lebih cocok untuk adanya variasi waktu.

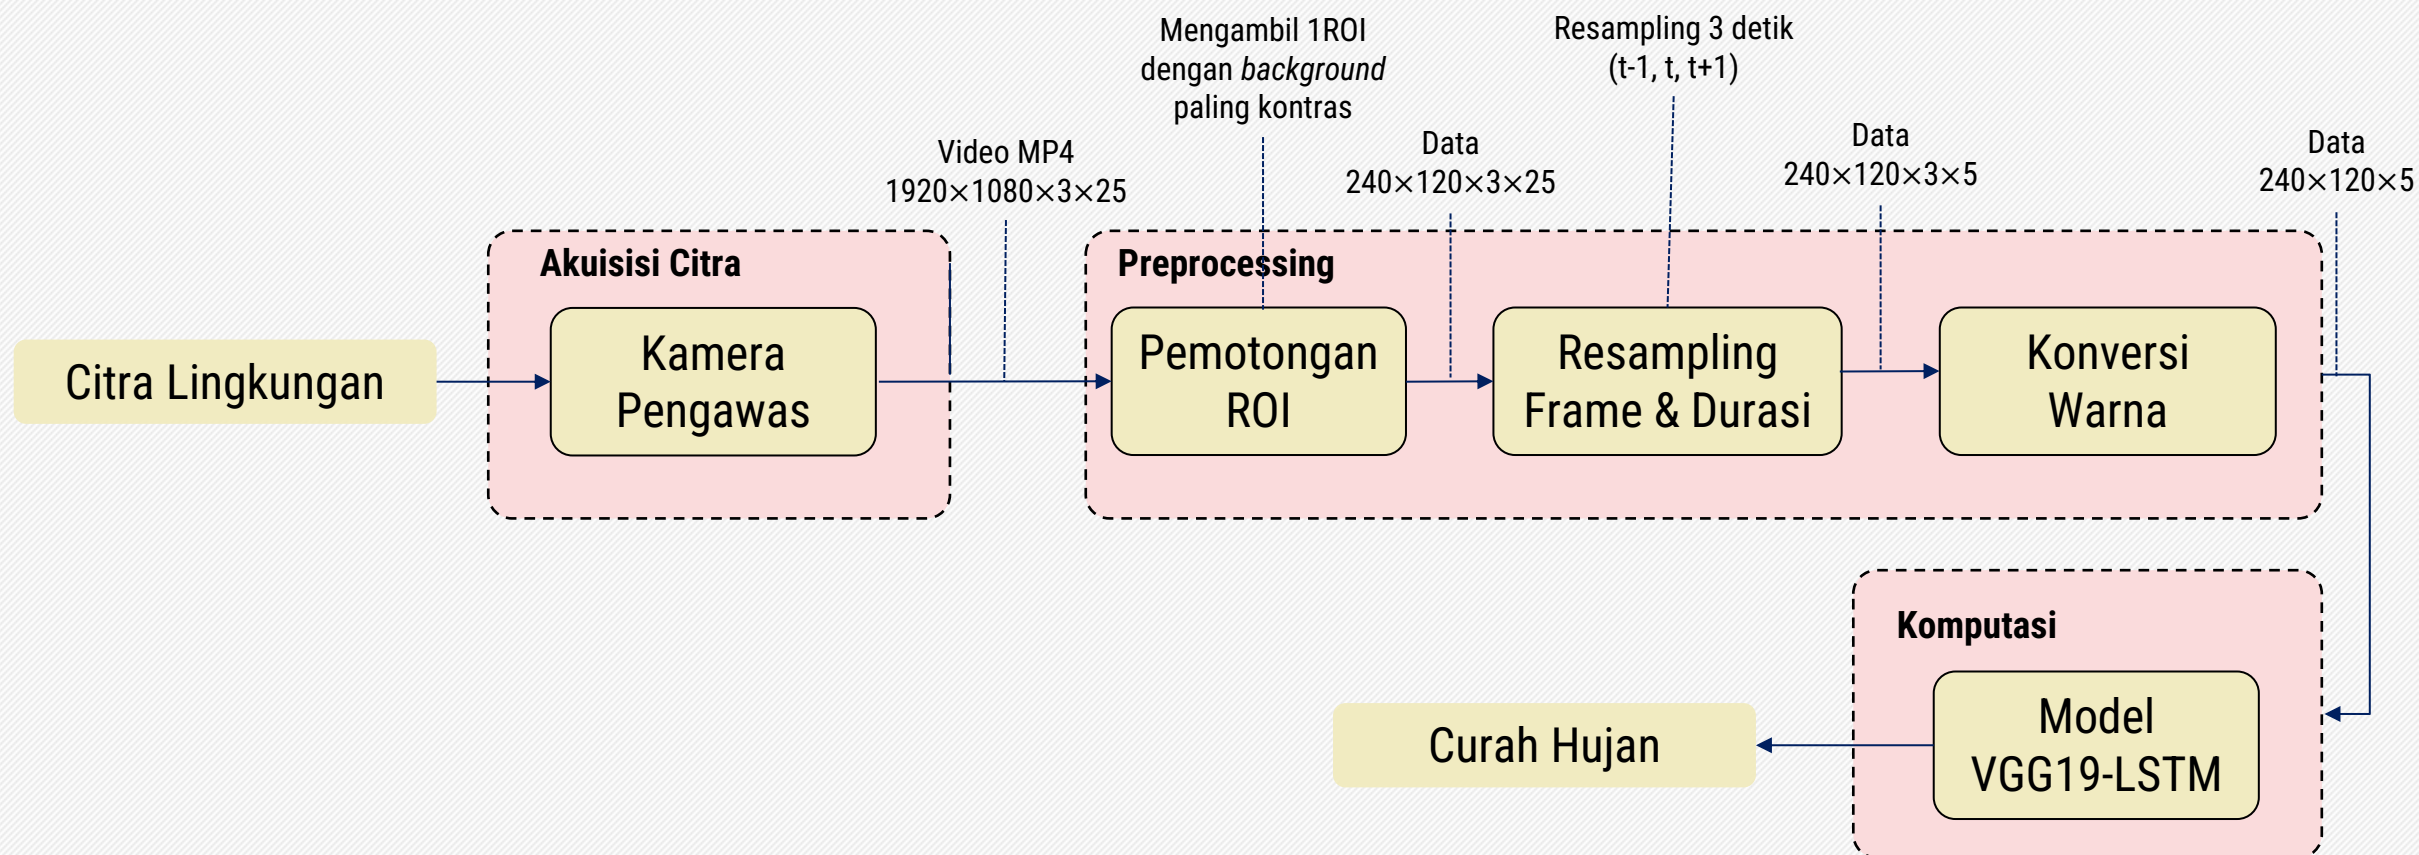
Metodologi

Estimasi Curah Hujan Berbasis Convolutional Neural Network - Long Short Term Memory (CNN-LSTM) dengan Input Video Kamera Pengawas

Metodologi

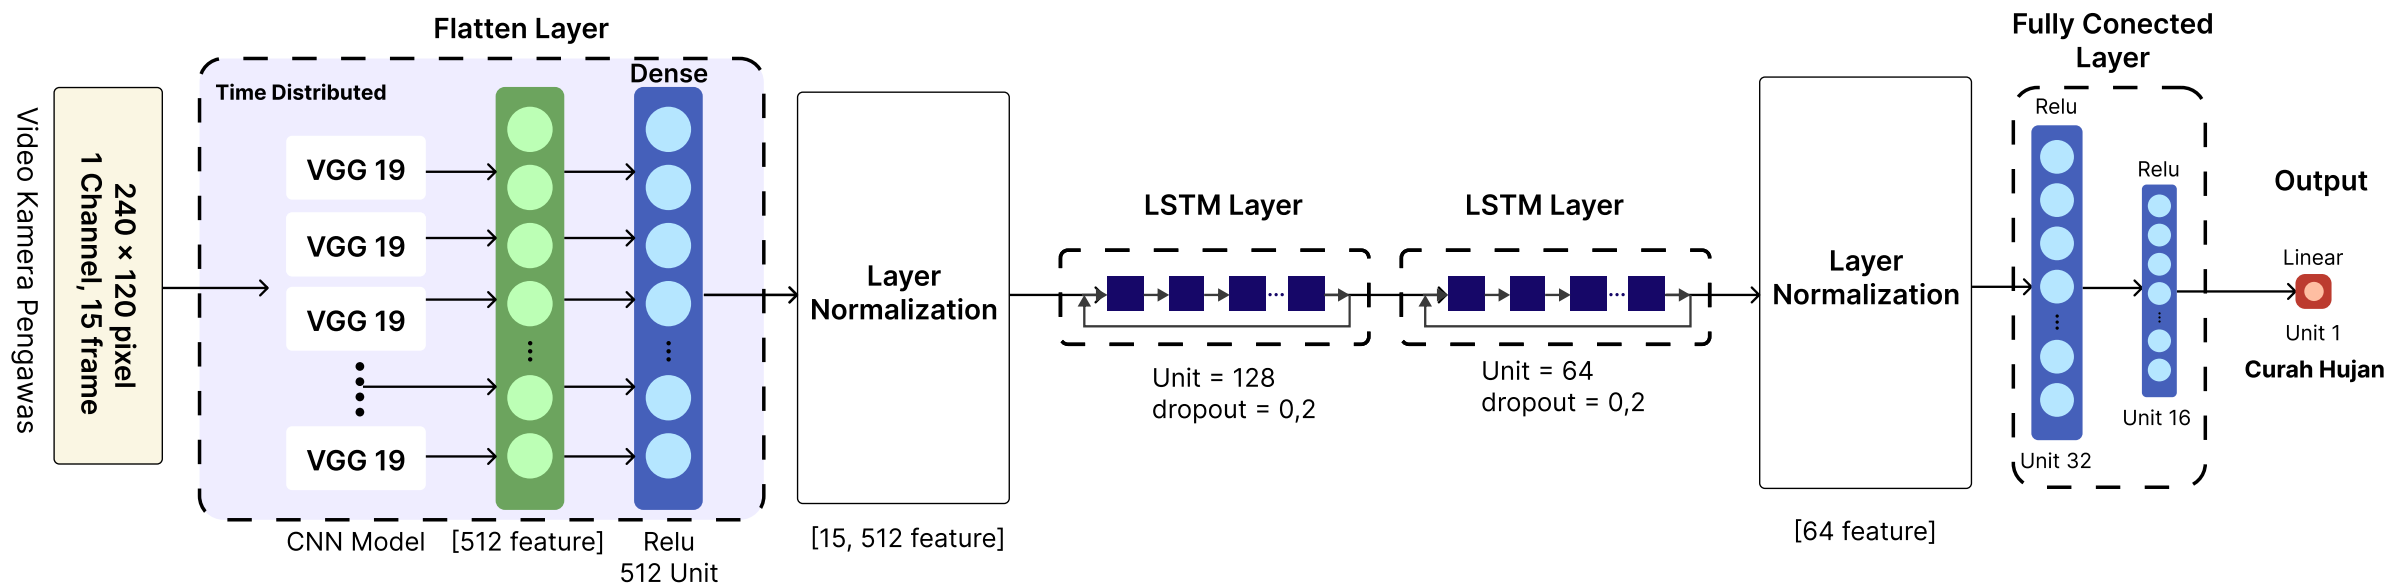
Rancangan Sistem Estimasi Curah Hujan





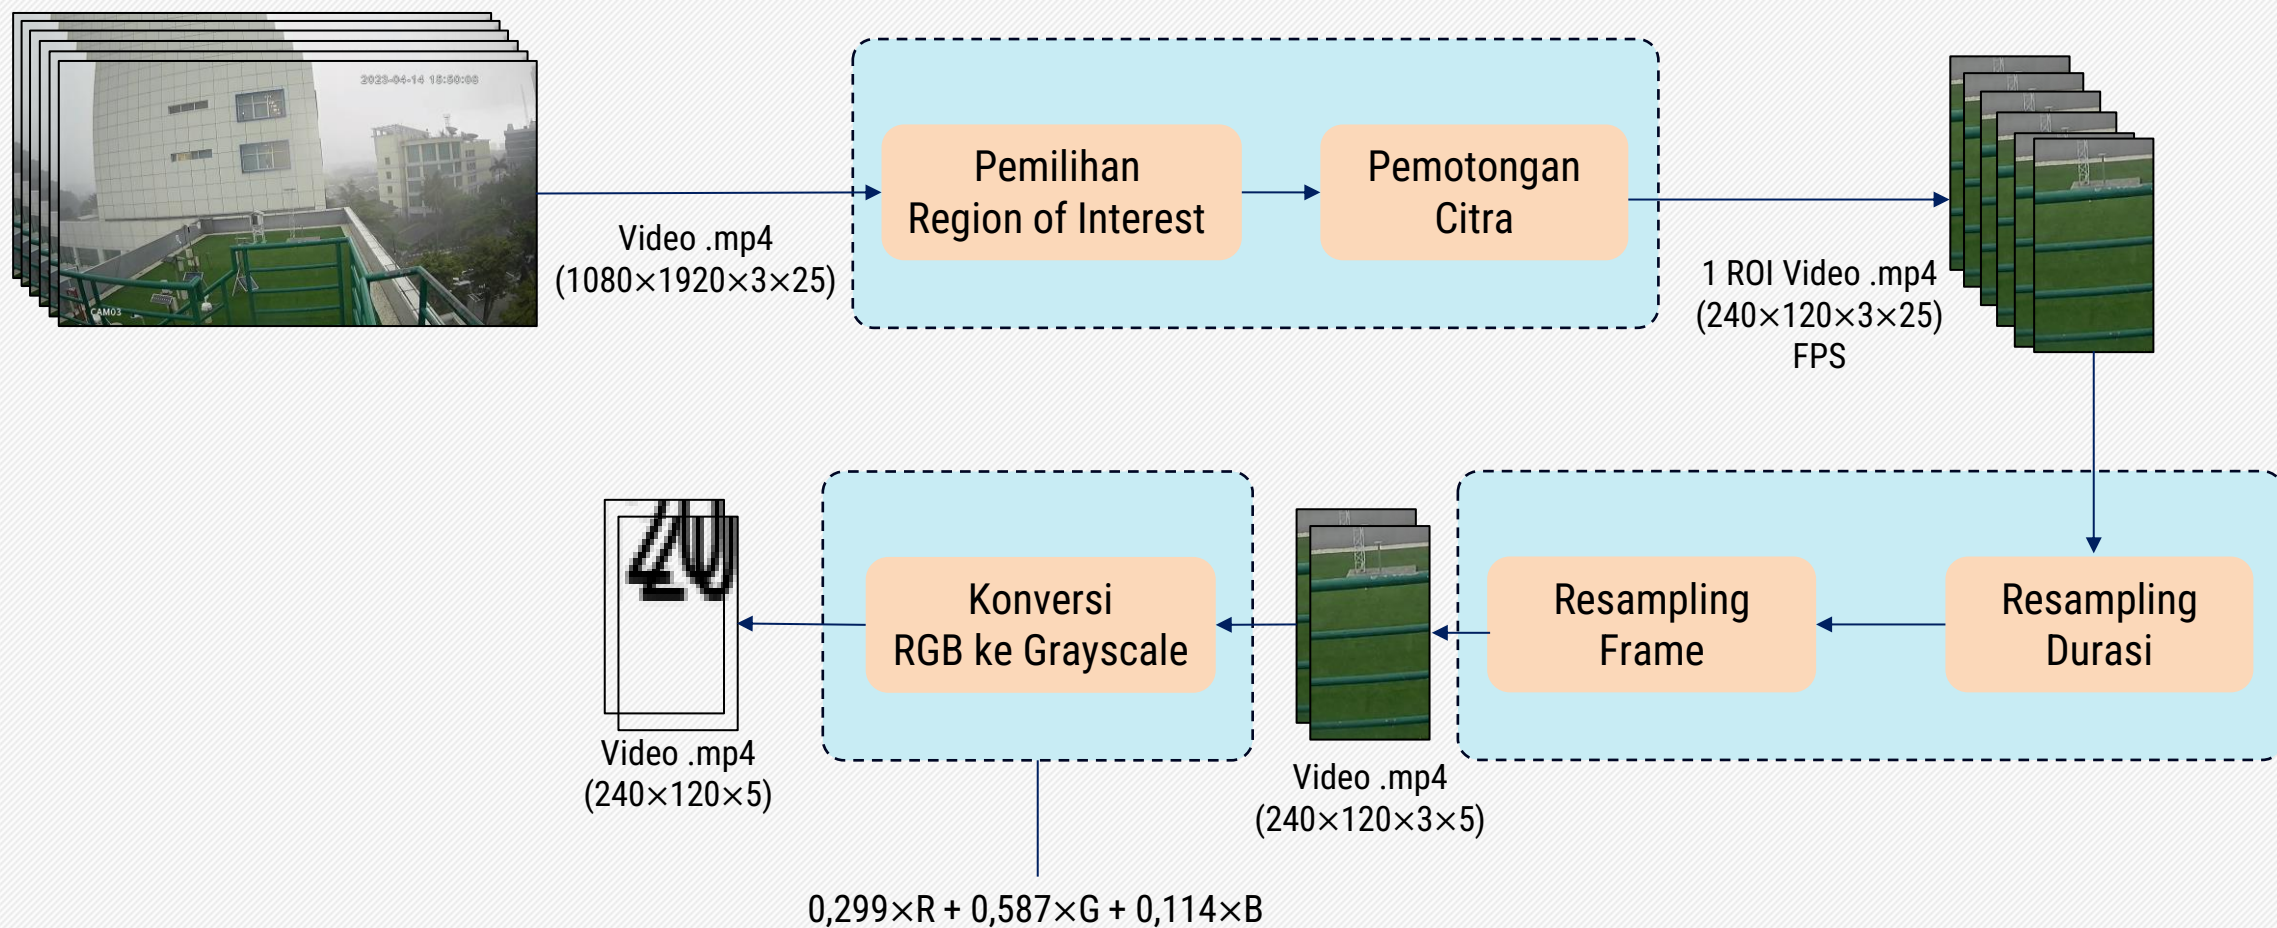
Metodologi

Arsitektur Model VGG19-LSTM



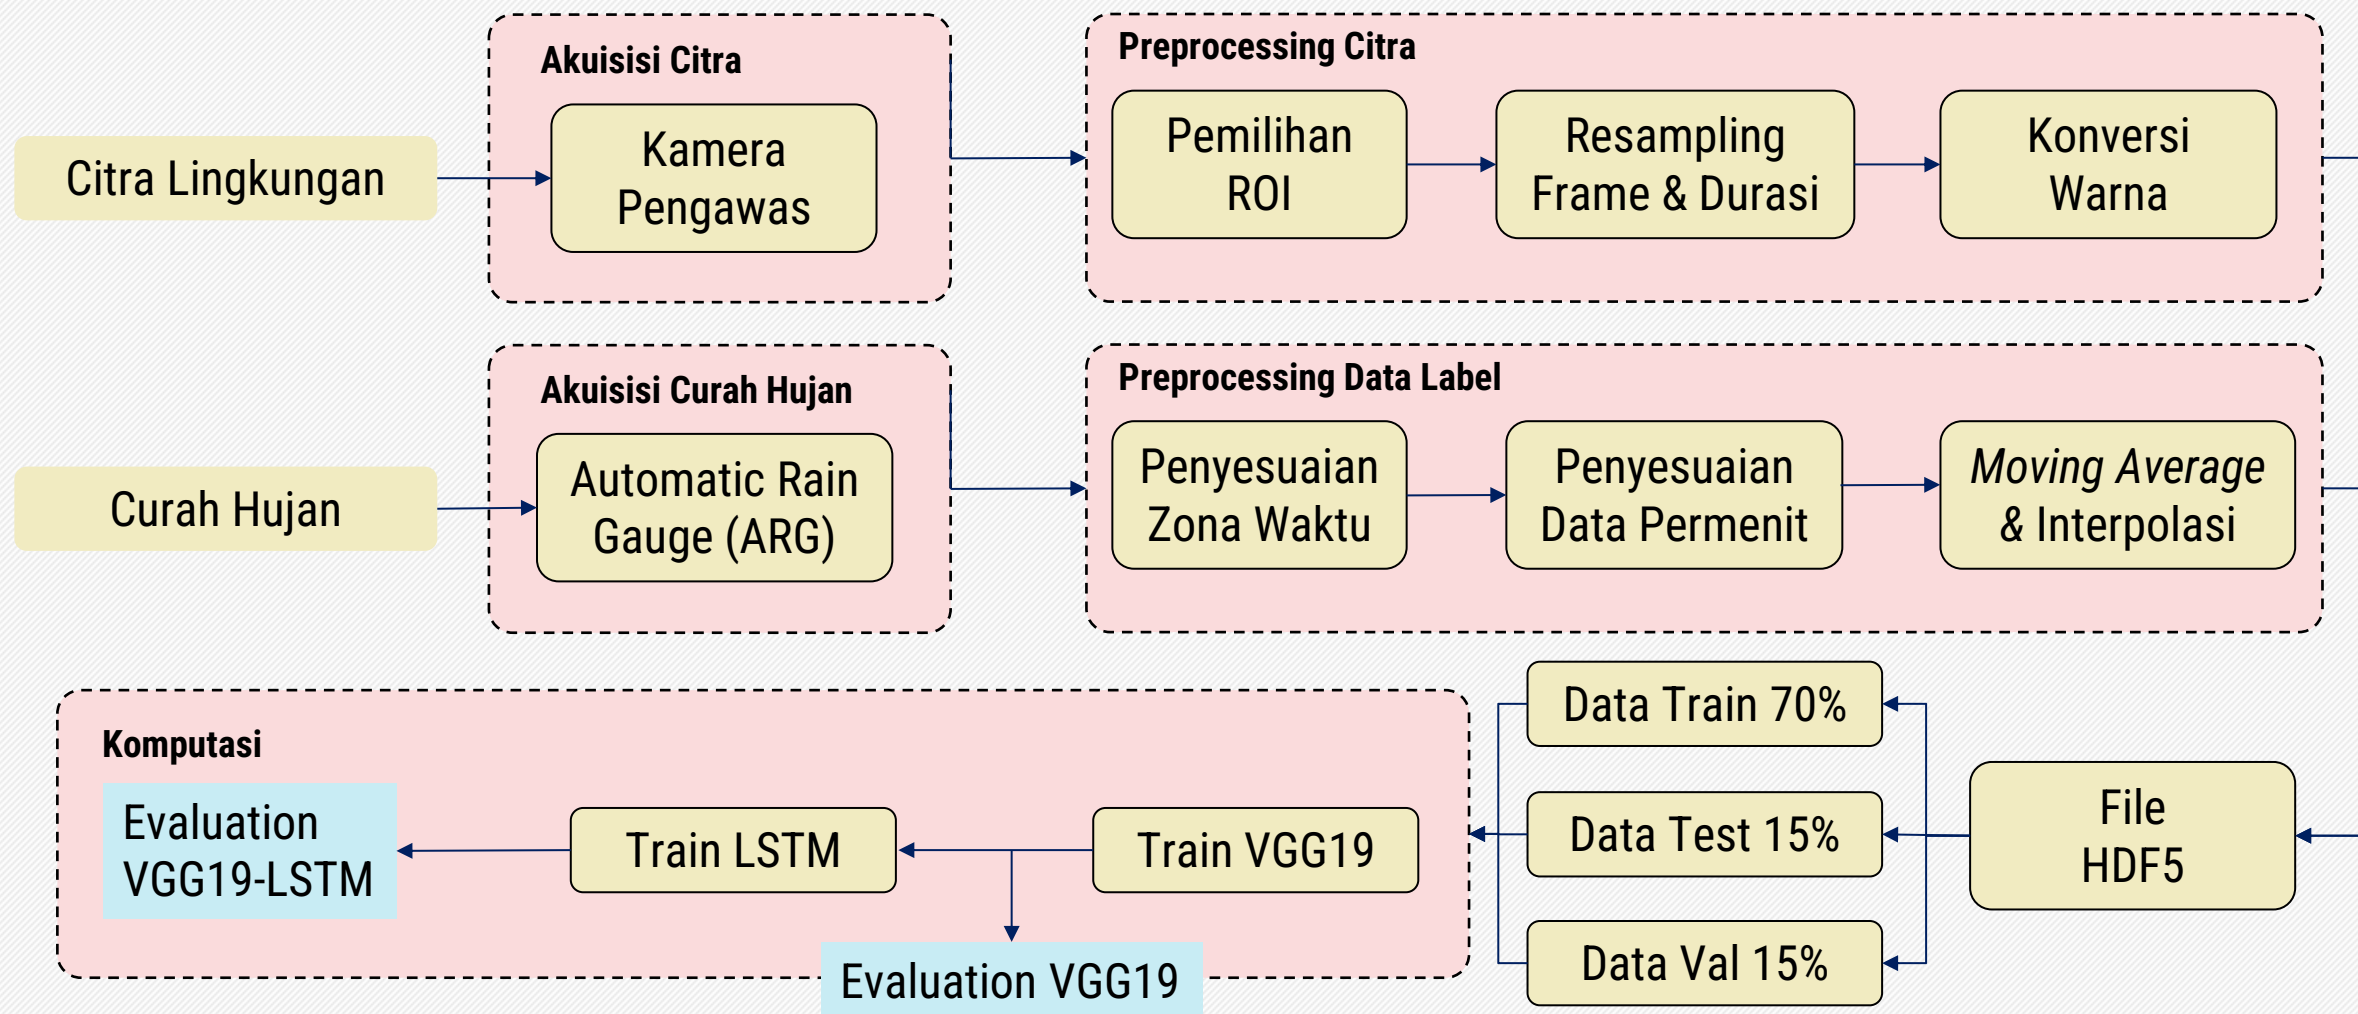
Metodologi

Preprocessing Citra



Metodologi

Rancangan Eksperimen Estimasi Curah Hujan



Metodologi

Pengaturan Perangkat Eksperimen

Spesifikasi ARG	Detail
Resolusi	0,2 mm/menit
Nilai Maksimum	4 mm/menit
Tinggi	350 mm
Diameter	200 mm
Spesifikasi Kamera	Detail
Resolusi	1920×1080; 5,2 MP
Framerate	25 fps
Format Video	MP4
Sensor	½ AGC On, 5MP SmartSens CMOS Sensor

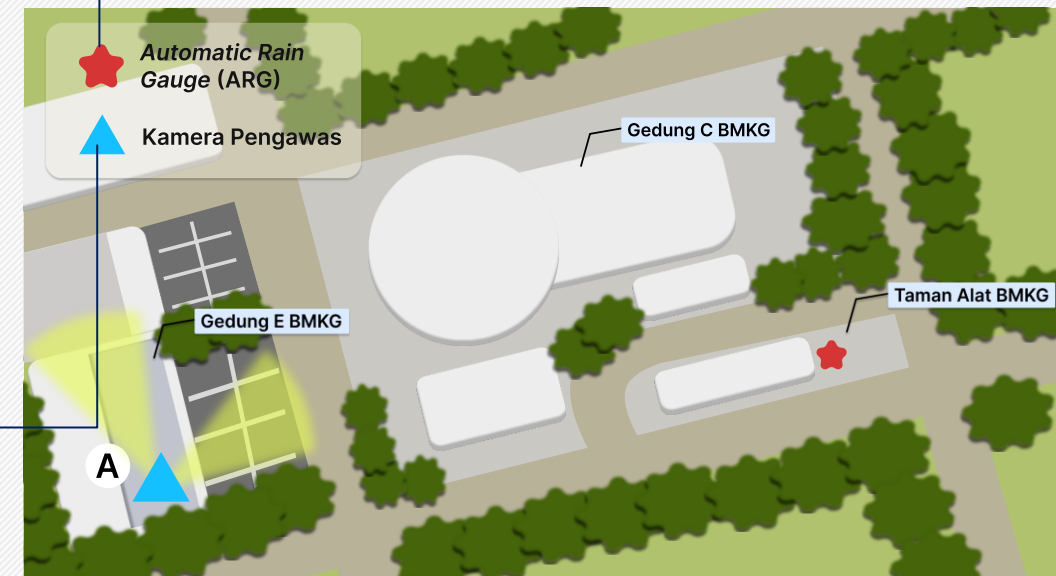
Automatic Rain Gauge



Kamera Pengawas



Spesifikasi Komputer	Detail
Processor	Intel I7-11700F
VGA	NVIDIA RTX 3090TI VRAM 24GB
RAM	32GB
Storage	SSD 9TB



Denah rancangan penempatan perangkat keras di area gedung BMKG Kemayoran

Metodologi

Rancangan Pembuatan Dataset

Eksperimen A: Variasi Input Temporal

Konfigurasi Frame dan Durasi	Konfigurasi Waktu	Train (event)	Test (event)	Validasi (event)
5 Fps, 1 Detik	All-Day	18.500	4.000	4.000
10 Fps, 1 Detik	All-Day	11.000	2.400	2.400
5 Fps, 3 Detik	All-Day	9.500	1.900	1.900
5 Fps, 3 Detik (Data kecil)	All-Day	5.100	1.100	1.100

Sinkronisasi dengan label

File dengan format HDF5

All-Day

40% Siang (07.00-17.00)
10% Sore (17.00-19.00)
40% Malam (19.00-05.00)
10% Pagi (05.00-07.00)

Eksperimen B: Variasi Perubahan Waktu

Konfigurasi Waktu	Konfigurasi Frame dan Durasi	Train (event)	Test (event)	Validasi (event)
Siang	5 Fps, 3 Detik	9.500	1.900	1.900
Malam	5 Fps, 3 Detik	9.500	1.900	1.900
All-Day	5 Fps, 3 Detik	9.500	1.900	1.900

Sinkronisasi dengan label

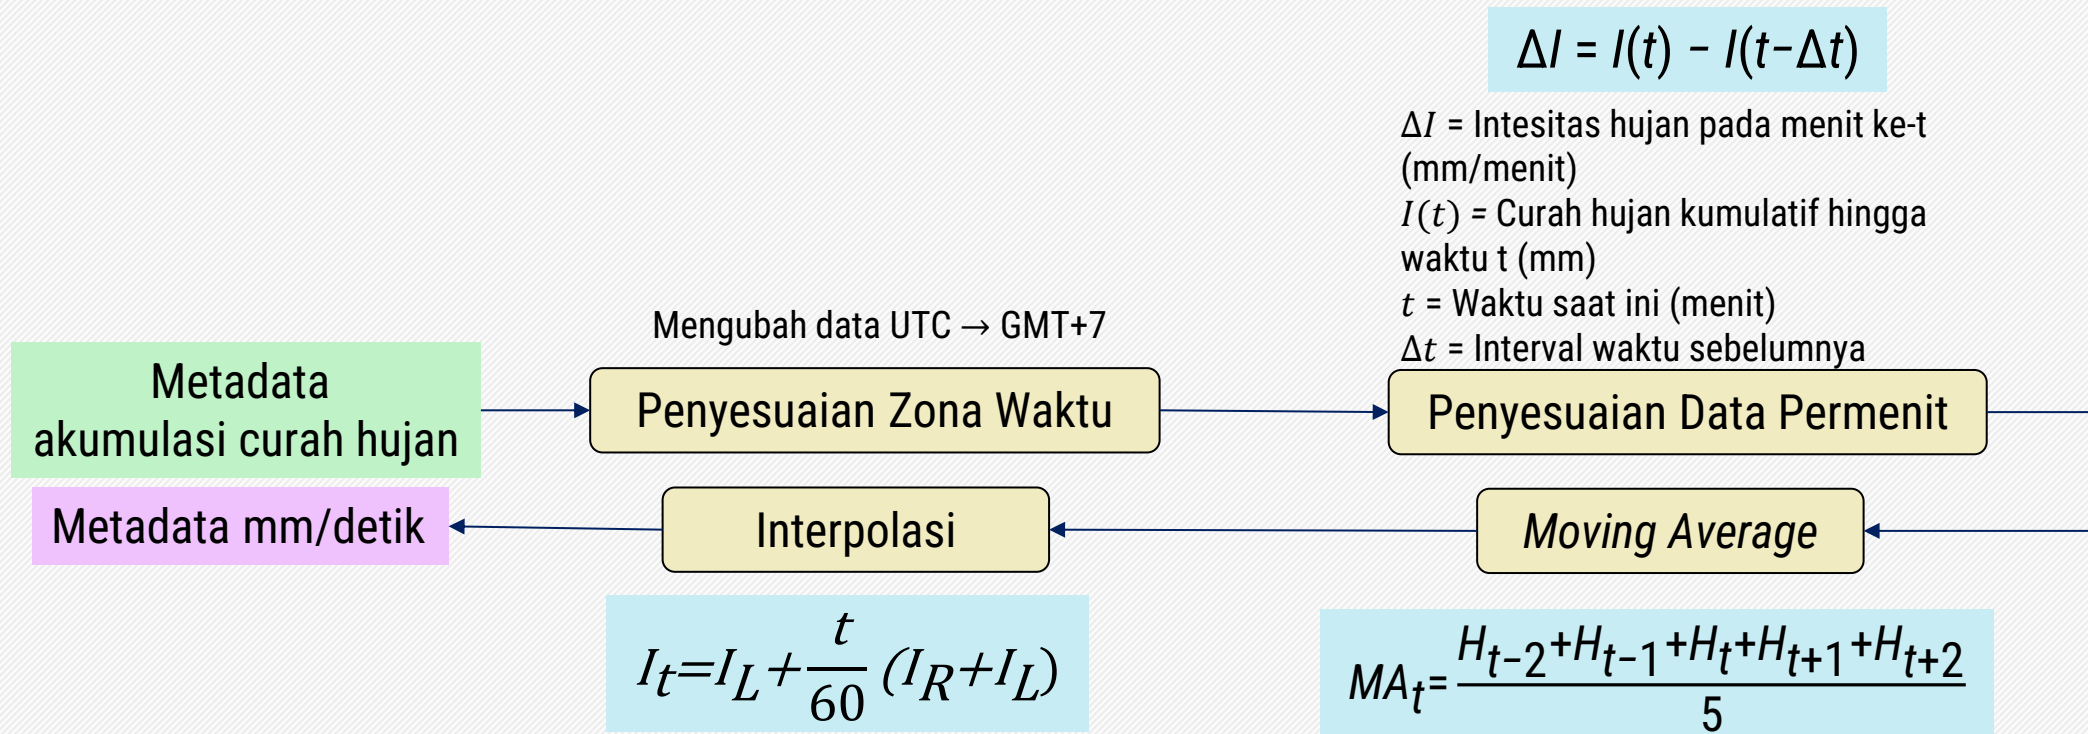
File dengan format HDF5

Feature Extractor VGG19

Model VGG19 hanya menggunakan satu frame: frame pertama untuk durasi 1 detik, dan frame ke-6 (tengah) untuk durasi 3 detik

Metodologi

Preprocessing Data Curah Hujan



Metodologi

Metode Evaluasi

Koefisien Determinasi

$$R^2 = \frac{[\sum_{i=1}^n (y_i - \bar{y}) \sum_{i=1}^n (y_i - \hat{y}_i)]^2}{\sum_{i=1}^n (y_i - \bar{y})^2 \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Mean Absolute Error

$$MAE = \frac{1}{N} \sum_{i=1}^n |\hat{y}_i - y_i|$$

Mean Arctangent Absolute Percentage Error (MAAPE)

$$MAAPE = \frac{1}{N} \sum_{i=1}^n \arctan \left(\left| \frac{\hat{y}_i - y_i}{y_i} \right| \right)$$

Nash-Sutcliffe Efficiency (NSE)

$$NSE = \frac{1}{N} - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Kling-Gupta Efficiency (KGE)

$$KGE = 1 - \sqrt{(r-1)^2 + (\alpha-1)^2 + (\beta-1)^2}$$

(Rajabi et al., 2024).

Simbol	Deskripsi
N	Jumlah total data atau sampel (misalnya jumlah frame atau waktu)
y_i	Nilai ground truth pada sampel ke-i
\hat{y}_i	Nilai prediksi model pada sampel ke-i
\bar{y}	Rata-rata dari semua nilai aktual
$\bar{\hat{y}}$	Rata-rata dari semua nilai prediksi
r	Korelasi Pearson antara prediksi dan nilai
α	Rasio standar deviasi prediksi terhadap aktual
β	Rasio rata-rata prediksi terhadap rata-rata aktual

Hasil dan Pembahasan

Estimasi Curah Hujan Berbasis Convolutional Neural Network - Long Short Term Memory (CNN-LSTM) dengan Input Video Kamera Pengawas

Hasil

Citra pada Dua Kamera Pengawas



Hasil kamera pertama



Hasil kamera Kedua

Hasil

Citra pada Dua Ruang Warna



Citra *grayscale*



Citra *RGB*

Hasil

Citra pada Berbagai Kondisi Waktu



Sore
0,21 mm/detik



Malam
0,75 mm/detik



Pagi
0,51 mm/detik



Siang
0,91 mm/detik

Hasil

Kondisi Citra pada Berbagai Kondisi Hujan



Tidak ada hujan
0,00 mm/detik




Hujan ringan
0,12 mm/detik



Hujan lebat
1,01 mm/detik

Hasil

Pemrosesan Data *Automatic Rain Gauge* (1/2)



Moving Average

Sebelum Moving Average


Statistik	Detail
Jumlah <i>Sample</i>	56
Rata-Rata Curah Hujan	0,30 mm
Curah Hujan Min	0,00 mm
Curah Hujan Max	1,00 mm

Sesudah Moving Average

Statistik	Detail
Jumlah <i>Sample</i>	56
Rata-Rata Curah Hujan	0,30 mm
Curah Hujan Min	0,00 mm
Curah Hujan Max	0,84 mm

Hasil

Pemrosesan Data *Automatic Rain Gauge* (2/2)



Sebelum Interpolasi


Statistik	Detail
Jumlah <i>Sample</i>	56
Rata-Rata Curah Hujan	0,30 mm
Curah Hujan Min	0,00 mm
Curah Hujan Max	1,00 mm

Sesudah Interpolasi

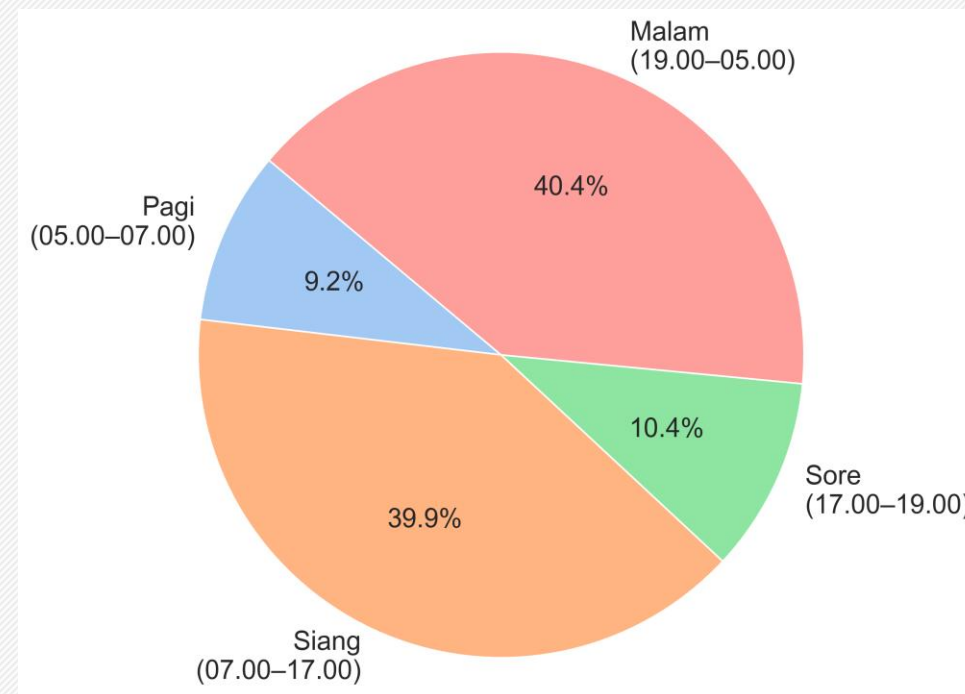
Statistik	Detail
Jumlah <i>Sample</i>	3361
Rata-Rata Curah Hujan	0,30 mm
Curah Hujan Min	0,00 mm
Curah Hujan Max	0,84 mm

Hasil

Distribusi Curah Hujan pada Dataset *All-Day*



Distribusi kelas curah hujan



Distribusi label waktu

Hasil

Hasil Evaluasi Berdasarkan Input Temporal (1/2)


Tabel hasil *evaluation metrics* model VGG dan VGG-LSTM

Konfigurasi	Model	R2 Score		
		Train	Val	Test
5 Fps, 1 Detik	VGG	0,9993	0,9614	0,9630
	VGG-LSTM	0,9899	0,9587	0,9621
10 Fps, 1 Detik	VGG	0,9992	0,9529	0,9502
	VGG-LSTM	0,9761	0,9472	0,9431
5 Fps, 3 Detik	VGG	0,9994	0,9544	0,9485
	VGG-LSTM	0,9974	0,9629	0,9602
5 Fps, 3 Detik (Data kecil)	VGG	0,8405	0,4241	0,4969
	VGG-LSTM	0,8388	0,4686	0,5254

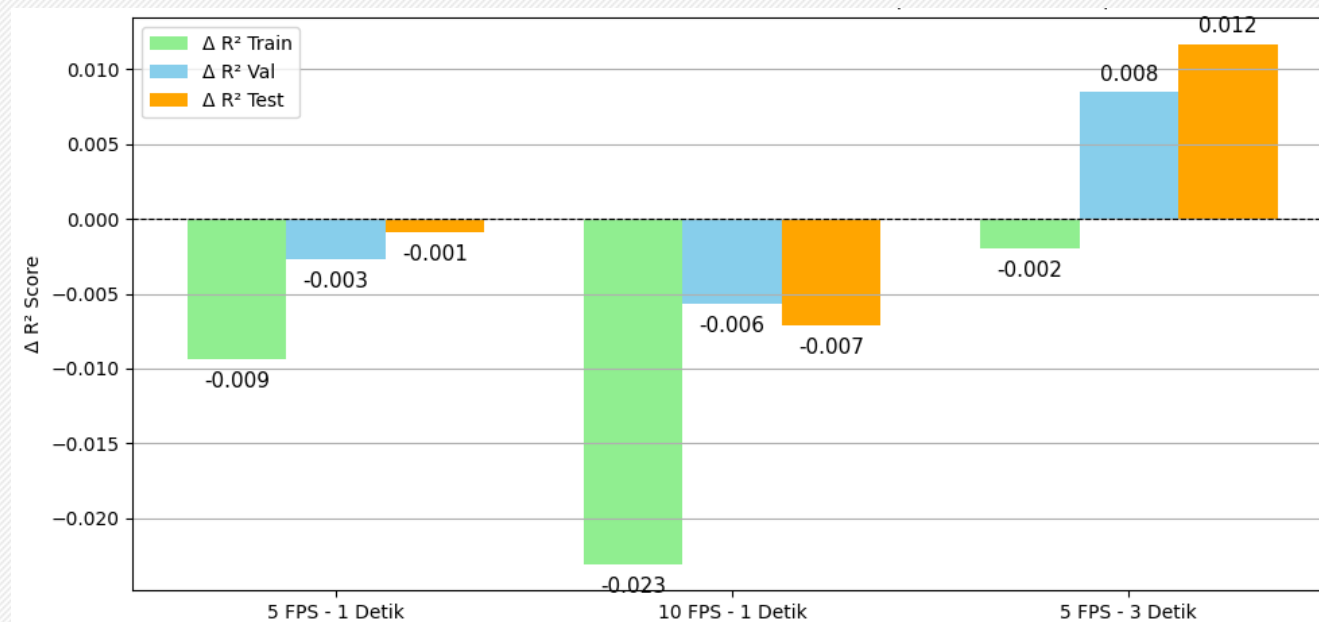
Konfigurasi utama memberikan **performa yang serupa**, mengindikasikan bahwa setelah melewati **threshold sekitar 9000 sampel**, penambahan data **tidak** lagi memberikan **peningkatan performa** yang signifikan.

Hasil

Hasil Evaluasi Berdasarkan Input Temporal (2/2)



Grafik perbandingan tingkat *overfitting* pada ketiga konfigurasi dataset

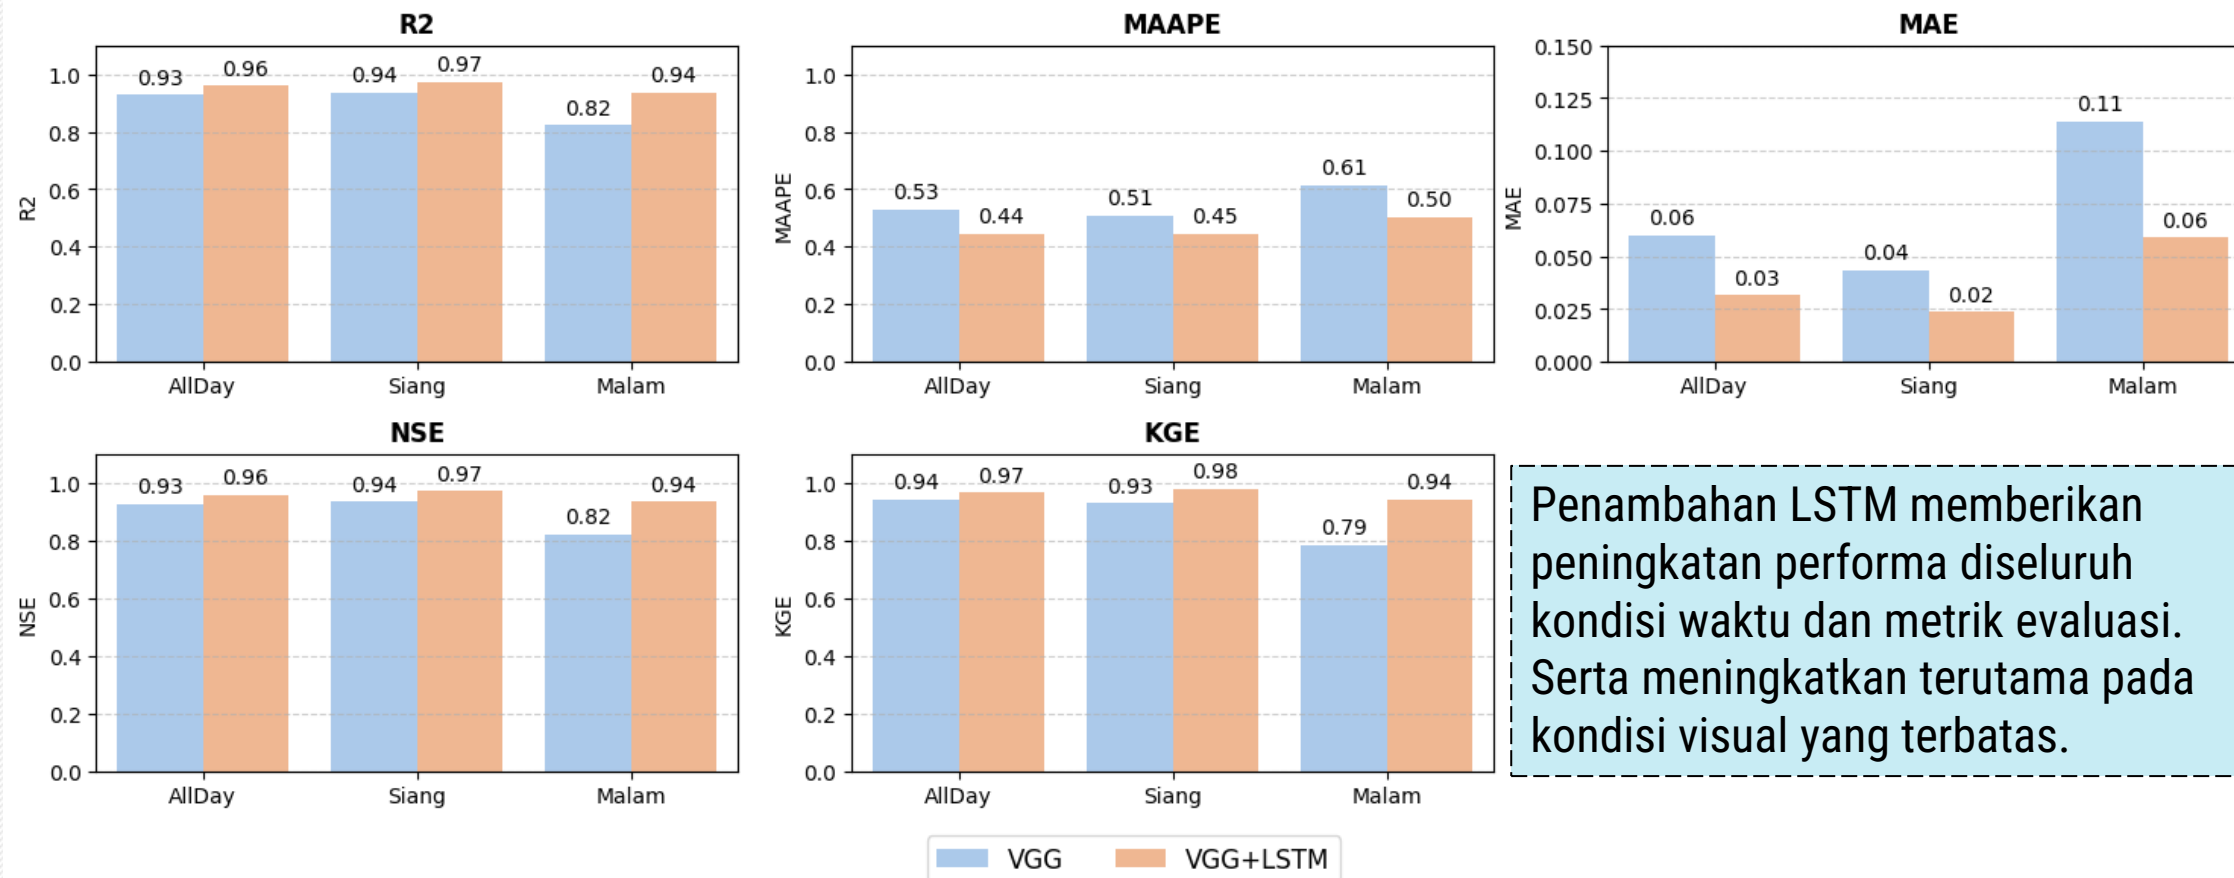


Grafik perubahan R^2 score setelah penambahan LSTM

LSTM menurunkan **overfitting** di semua konfigurasi. Durasi **3 detik** memberi **peningkatan R^2** paling konsisten, menunjukkan bahwa durasi lebih informatif dibanding sekadar menambah FPS.

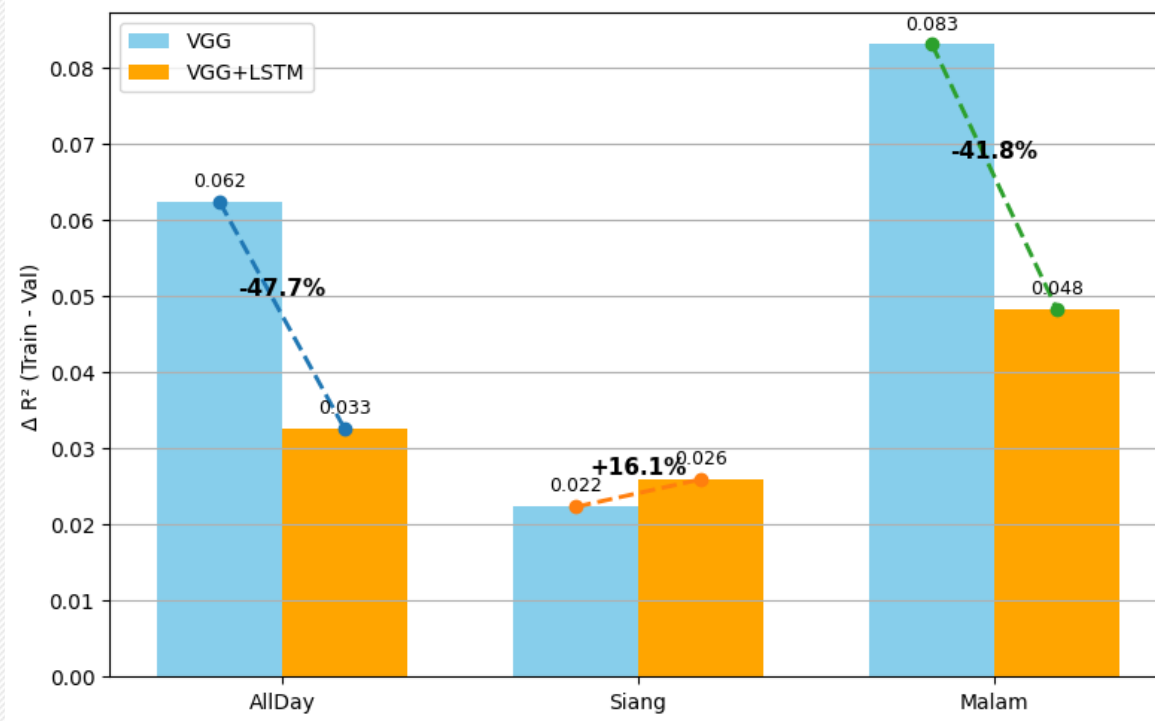
Hasil

Grafik evaluation metrics pada model VGG19 dan VGG19+LSTM pada *Testing Dataset*

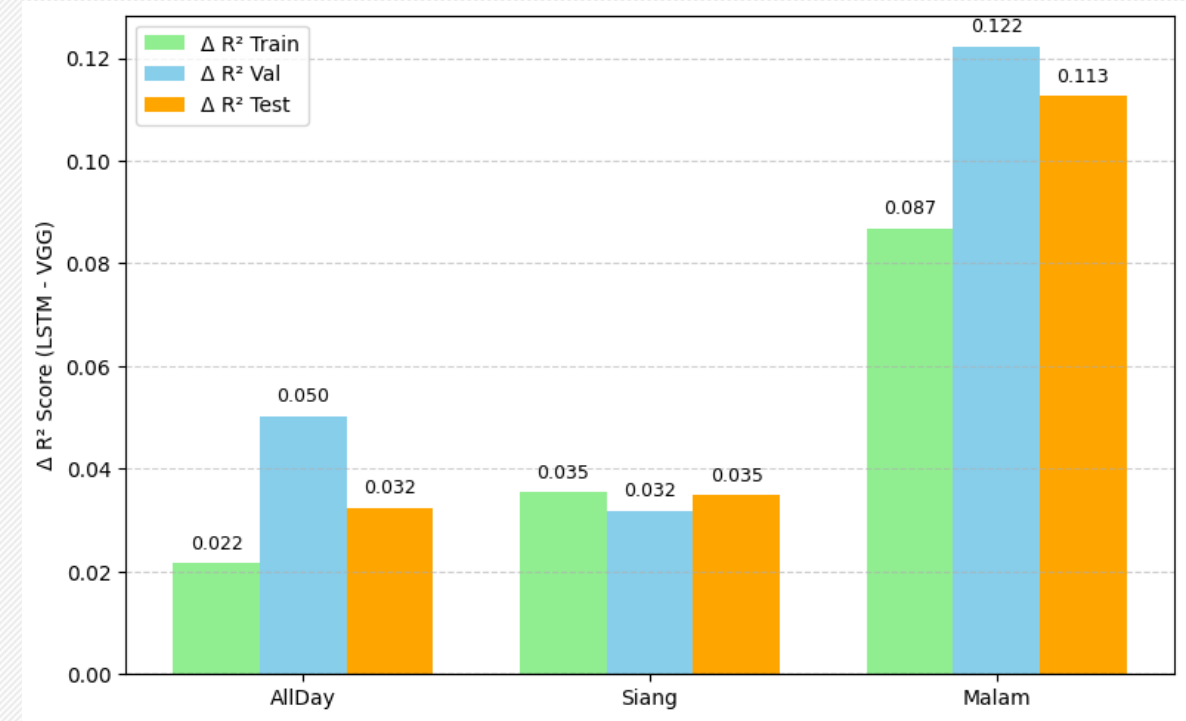


Hasil

Hasil Evaluasi Berdasarkan Kondisi Waktu



Grafik tingkat overfitting untuk waktu allday, siang, dan malam

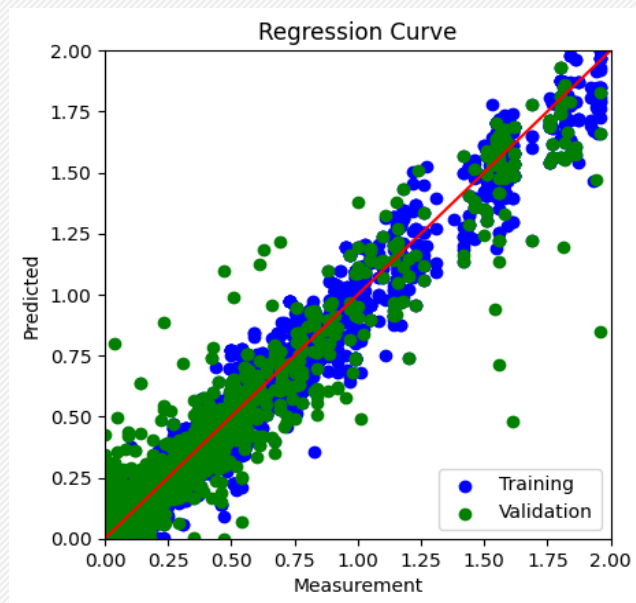


Grafik selisih R² score untuk waktu allday, siang, dan malam

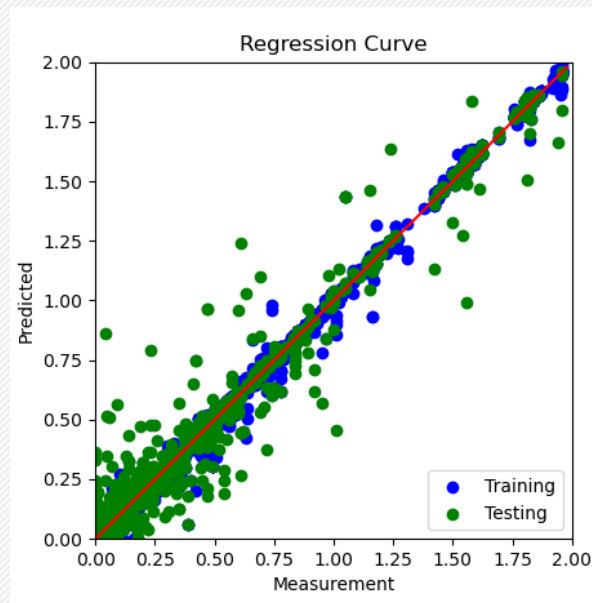
LSTM secara **signifikan menurunkan overfitting**, terutama pada data all-day dan malam hari. Peningkatan performa paling besar terjadi pada malam hari, menunjukkan bahwa **LSTM efektif** dalam menangani **kondisi visual yang buruk**

Hasil

Konfigurasi Terbaik



Kurva regresi VGG19



Kurva regresi VGG19+LSTM

Evaluation Metrics VGG19+LSTM

Metrik	Train	Val	Test
R ² Score	0.9974	0.9649	0.9674
NSE	0.9974	0.9649	0.9674
MAE	0.0093	0.0310	0.0306
MAAPE	0.3752	0.4510	0.4509
KGE	0.9915	0.9777	0.9825

Konfigurasi model dan *dataset*

Kategori	Keterangan
Model	VGG19 + LSTM
Input Resolusi	240 × 120 piksel
Durasi Input	3 detik (15 frame, 5 FPS)
Dataset	Allday (22 GB)
Jumlah Sampel	Train: 9428 • Val: 1903 • Test: 1903
Training Time	200 Menit

Kesimpulan

Estimasi Curah Hujan Berbasis Convolutional Neural Network - Long Short Term Memory (CNN-LSTM) dengan Input Video Kamera Pengawas

Kesimpulan

1. **Model CNN-LSTM** untuk estimasi curah hujan berhasil dikembangkan menggunakan video kamera pengawas yang diubah menjadi citra **grayscale** yang berurutan berukuran 240×120 piksel, berdurasi **3 detik (15 frame, 5 FPS)**. Arsitektur menggunakan **VGG19** (tanpa FC) untuk ekstraksi fitur spasial dan **dua lapisan LSTM** untuk pola temporal.
2. Konfigurasi input terbaik diperoleh pada skenario 5 FPS – 3 detik, yang menghasilkan peningkatan performa paling konsisten (ΔR^2 **Test: +0,0423**) dan tingkat overfitting yang rendah (**0,0345**). Sebaliknya, durasi pendek dengan FPS tinggi justru menghasilkan data **redundan antarframe**, sehingga menurunkan akurasi.
3. Model menunjukkan *robustness* terhadap variasi waktu, dengan performa tinggi pada skenario **all-day**:
 - $R^2 = 0,9673$
 - MAE = 0,0309 mm/detik

Referensi

Estimasi Curah Hujan Berbasis Convolutional Neural Network - Long Short Term Memory (CNN-LSTM) dengan Input Video Kamera Pengawas

Referensi

- Bartholomew, M. J. (2016). *Optical Rain Gauge Instrument Handbook*.
- Behrangi, A., Sorooshian, S., & Hsu, K. lin. (2012). Summertime evaluation of REFAME over the Unites States for near real-time high resolution precipitation estimation. *Journal of Hydrology*, 456–457, 130–138. <https://doi.org/10.1016/j.jhydrol.2012.06.033>
- Boominathan, V., Adams, J. K., Asif, M. S., Avants, B. W., Robinson, J. T., Baraniuk, R. G., Sankaranarayanan, A. C., & Veeraraghavan, A. (2016). Lensless Imaging: A computational renaissance. *IEEE Signal Processing Magazine*, 33(5), 23–35. <https://doi.org/10.1109/MSP.2016.2581921>
- Bourree, L. E. (2014). Performance of PHOTONIS' low light level CMOS imaging sensors for long range observation. *Image Sensing Technologies: Materials, Devices, Systems, and Applications*, 9100, 910004. <https://doi.org/10.1117/12.2050614>
- Chauhan Nitin Kumar, & Sign Krishna. (2018). *A Review on Conventional Machine Learning vs Deep Learning*. IEEE.
- Dong-Bin Shin, & Y.-R. L. (2015). *Radio Science Conference (URSI AT-RASC), 2015 1st URSI Atlantic : date 16-24 May 2015*. IEEE.
- Duthon, P., Bernardin, F., Chausse, F., & Colomb, M. (2018). Benchmark for the robustness of image features in rainy conditions. *Machine Vision and Applications*, 29(5), 915–927. <https://doi.org/10.1007/s00138-018-0945-8>
- Editor Wolfgang Walz, S. (2023). *Machine Learning for Brain Disorders*. <http://www.springer.com/series/7657>
- Faiz, A., Gopalakrishna, K., Agarwal, A., Suchithra, R., Saini, P., & Ayus, I. (2025). LSTM-CNN Ensemble Methods for Predicting Malignant Brain Tumors. 2025 International Conference on Automation and Computation, AUTOCOM 2025, 881–886. <https://doi.org/10.1109/AUTOCOM64127.2025.10957702>
- Ferraro, R. R., Skofronick-Jackson, G., Hong, Y., & Zhang, K. (2017). Precipitation. In *Comprehensive Remote Sensing* (Vols. 1–9, pp. 4–24). Elsevier. <https://doi.org/10.1016/B978-0-12-409548-9.10385-9>
- Fiallos-Salguero, M., Khu, S.-T., Guan, J., Wang, T., & Wang, M. (2024). Computer Vision-Based Method for Rainfall Estimation Using CCTV Cameras and 2 Smartphone Videos. <https://ssrn.com/abstract=4691544>

Referensi

- Ghodke, S., & Nandgave, S. (2023). Brain MRI Classification Using Convolutional Neural Networks and VGG19: A Deep Learning Approach for Accurate Brain Disease Diagnosis. 2023 International Conference on Integration of Computational Intelligent System, ICICIS 2023. <https://doi.org/10.1109/ICICIS56802.2023.10430304>
- Goormans, T. (2017). Analysis of local weather radar data in support of sewer system modelling. <https://www.researchgate.net/publication/318108618>
- Guo, W., Jin, L., & Xiong, J. (2007). Driving techniques for high frame rate CCD camera. Electronic Imaging and Multimedia Technology V, 6833, 683339. <https://doi.org/10.1117/12.760841>
- Gupta, H. V., Kling, H., Yilmaz, K. K., & Martinez, G. F. (2009). Decomposition of the mean squared error and NSE performance criteria: Implications for improving hydrological modelling. Journal of Hydrology, 377(1–2), 80–91. <https://doi.org/10.1016/j.jhydrol.2009.08.003>
- Herrmann, C., Ruf, M., & Beyerer, J. (2018). CNN-based thermal infrared person detection by domain adaptation. Proc.SPIE, 10643, 1064308. <https://doi.org/10.1117/12.2304400>
- Hong, Y., & Zhang, Y. (2014). Spatiotemporal Scales of Remote Sensing Precipitation. Scale Issues in Remote Sensing. In Seo and Krajewski.
- Ikeuchi, K., Matsushita, Y., Sagawa, R., Kawasaki, H., Mukaigawa, Y., Furukawa, R., & Miyazaki, D. (2020). Advances in Computer Vision and Pattern Recognition Active Lighting and Its Application for Computer Vision 40 Years of History of Active Lighting Techniques. <http://www.springer.com/series/4205>
- Indikar, M., Dandgall, S. M., & Baligar, V. P. (2024). Brain Tumor Classification Using Convolutional Neural Network. 2024 Second International Conference on Advances in Information Technology (ICAIT), 1–6. <https://doi.org/10.1109/ICAIT61638.2024.10690562>
- Iqbal, Saputro, A. H., Bustamam, A., Sopaheluwakan, A., & Trihadi, E. (2023). Rainfall Estimation Using Convolutional Neural Networks in Various Environmental Backgrounds. 2023 International Conference on Information Technology Research and Innovation, ICITRI 2023, 70–74. <https://doi.org/10.1109/ICITRI59340.2023.10249806>
- Jiang, S., Babovic, V., Zheng, Y., & Xiong, J. (2019). Advancing Opportunistic Sensing in Hydrology: A Novel Approach to Measuring Rainfall With Ordinary Surveillance Cameras. Water Resources Research, 55(4), 3004–3027. <https://doi.org/10.1029/2018WR024480>
- Khoirunisa, R. (2023). Urban Flood And Its Correlation With Built-Up Area In Semarang, Indonesia. Smart City, 3(2). <https://doi.org/10.56940/sc.v3.i2.2>

Referensi

- Kim, S., & Kim, H. (2016). A new metric of absolute percentage error for intermittent demand forecasts. *International Journal of Forecasting*, 32(3), 669–679. <https://doi.org/10.1016/j.ijforecast.2015.12.003>
- Kling, H., Fuchs, M., & Paulin, M. (2012). Runoff conditions in the upper Danube basin under an ensemble of climate change scenarios. *Journal of Hydrology*, 424–425, 264–277. <https://doi.org/10.1016/j.jhydrol.2012.01.011>
- Lami, H., & Pella, S. I. (n.d.). Disain Sistem Penginderaan Level Intensitas Curah Hujan berbasis Minicomputer. *Jurnal Media Elektro I*, VII(1).
- Lee, J., Byun, J., Baik, J., Jun, C., & Kim, H. J. (2023). Estimation of raindrop size distribution and rain rate with infrared surveillance camera in dark conditions. *Atmospheric Measurement Techniques*, 16(3), 707–725. <https://doi.org/10.5194/amt-16-707-2023>
- Li, Y., Tan, R. T., Guo, X., Lu, J., & Brown, M. S. (2016). Rain Streak Removal Using Layer Priors. *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, 2016-December, 2736–2744. <https://doi.org/10.1109/CVPR.2016.299>
- Liang, S., Zhu, B., Zhang, Y., Cheng, S., & Jin, J. (2020). A Double Channel CNN-LSTM Model for Text Classification. *Proceedings - 2020 IEEE 22nd International Conference on High Performance Computing and Communications, IEEE 18th International Conference on Smart City and IEEE 6th International Conference on Data Science and Systems, HPCC-SmartCity-DSS 2020*, 1316–1321. <https://doi.org/10.1109/HPCC-SmartCity-DSS50907.2020.00169>
- Lin, C. W., Lin, M., & Yang, S. (2020). SOPNET method for the fine-grained measurement and prediction of precipitation intensity using outdoor surveillance cameras. *IEEE Access*, 8, 188813–188824. <https://doi.org/10.1109/ACCESS.2020.3032430>
- Liu, S., Qiao, H., Yuan, L., Yuan, Y., & Liu, J. (2023). Research on data augmentation algorithm for time series based on deep learning. *KSII Transactions on Internet and Information Systems*, 17(6), 1530–1544. <https://doi.org/10.3837/tiis.2023.06.002>
- Mandl, W. (2005). 12 mega-pixel, 1,000 fps visible camera with a nanowatt A/D converter at each pixel. *Infrared Spaceborne Remote Sensing 2005*, 5883, 58830D. <https://doi.org/10.1117/12.626663>

Referensi

- Manuel, F. S., Khu, S. T., Guan, J., & Wang, M. (2025). Toward accurate and scalable rainfall estimation using surveillance camera data and a hybrid deep-learning framework. *Environmental Science and Ecotechnology*, 25. <https://doi.org/10.1016/j.esse.2025.100562>
- Meena, G., Mohbey, K. K., Indian, A., & Kumar, S. (2022). Sentiment Analysis from Images using VGG19 based Transfer Learning Approach. *Procedia Computer Science*, 204, 411–418. <https://doi.org/10.1016/j.procs.2022.08.050>
- Michaelides, S., Levizzani, V., Anagnostou, E., Bauer, P., Kasparis, T., & Lane, J. E. (2009). Precipitation: Measurement, remote sensing, climatology and modeling. *Atmospheric Research*, 94(4), 512–533. <https://doi.org/10.1016/j.atmosres.2009.08.017>
- Nasution, B. I., Saputra, F. M., Kurniawan, R., Ridwan, A. N., Fudholi, A., & Sumargo, B. (2022). Urban vulnerability to floods investigation in jakarta, Indonesia: A hybrid optimized fuzzy spatial clustering and news media analysis approach. *International Journal of Disaster Risk Reduction*, 83. <https://doi.org/10.1016/j.ijdrr.2022.103407>
- Pan, S., Yang, B., Wang, S., Guo, Z., Wang, L., Liu, J., & Wu, S. (2023). Oil well production prediction based on CNN-LSTM model with self-attention mechanism. *Energy*, 284. <https://doi.org/10.1016/j.energy.2023.128701>
- Pandurangan, K., & Nagappan, K. (2024). A Deep Assessment of Thermal Image-Base Object Detection for a Wide Range of Applications. 2nd International Conference on Artificial Intelligence and Machine Learning Applications: Healthcare and Internet of Things, AIMLA 2024. <https://doi.org/10.1109/AIMLA59606.2024.10531492>
- Phankokkruad, M., & Wacharawichanant, S. (2019). An Application of Convolutional Neural Network-Long Short-Term Memory Model for Service Demand Forecasting. *IEEE*.
- RadhaKrishna, M. V. V., Venkata Govindh, M., & Krishna Veni, P. (2021). A review on image processing sensor. *Journal of Physics: Conference Series*, 1714(1). <https://doi.org/10.1088/1742-6596/1714/1/012055>
- Rajabi, F., Faraji, N., & Hashemi, M. (2024). An efficient video-based rainfall intensity estimation employing different recurrent neural network models. *Earth Science Informatics*, 17(3), 2367–2380. <https://doi.org/10.1007/s12145-024-01290-x>

Referensi

- Ravindaran, R., Kasthuri, N., Preethi, S., Adithya, B., Gunaranjan, S. P., Dharanidharan, K., & Aravinth, S. (2023). Performance Analysis of a VGG based Deep Learning Model for Classification of Weeds and Crops. 2023 14th International Conference on Computing Communication and Networking Technologies, ICCCNT 2023. <https://doi.org/10.1109/ICCCNT56998.2023.10307169>
- Reis, A. A. dos, Weerts, A., Ramos, M. H., Wetterhall, F., & Fernandes, W. dos S. (2022). Hydrological data and modeling to combine and validate precipitation datasets relevant to hydrological applications. *Journal of Hydrology: Regional Studies*, 44. <https://doi.org/10.1016/j.ejrh.2022.101200>
- Ro, Y., Chang, K. H., Hwang, H., Kim, M., Cha, J. W., & Lee, C. (2024). Comparative study of rainfall measurement by optical disdrometer, tipping-bucket rain gauge, and weighing precipitation gauge. *Natural Hazards*, 120(3), 2829–2845. <https://doi.org/10.1007/s11069-023-06308-z>
- Rosato, A., Araneo, R., & Andreotti Amedo. (2019). 2-D Convolutional Deep Neural Network for Multivariate Energy Time Series Prediction. *IEEE*.
- Sak, H., Senior, A., & Beaufays, F. (2014). Long short-term memory recurrent neural network architectures for large scale acoustic modeling. *Proceedings of the Annual Conference of the International Speech Communication Association, INTERSPEECH*, 338–342. <https://doi.org/10.21437/interspeech.2014-80>
- Sawant, S., & Ghonge, P. A. (2013). Estimation of Rain Drop Analysis Using Image Processing. In *International Journal of Science and Research (IJSR) ISSN (Vol. 4)*. www.ijsr.net
- Segovia-Cardozo, D. A., Bernal-Basurco, C., & Rodriguez-Sinobas, L. (2023). Effect of rainfall intensity on the mechanical biases of tipping bucket rainfall measurements. 2023 IEEE International Workshop on Metrology for Agriculture and Forestry, MetroAgriFor 2023 - Proceedings, 575–580. <https://doi.org/10.1109/MetroAgriFor58484.2023.10424058>
- Shalaby, Y., Alkhatib, M. I. I., Talei, A., Chang, T. K., Chow, M. F., & Pauwels, V. R. N. (2024). Estimating Rainfall Intensity Using an Image-Based Convolutional Neural Network Inversion Technique for Potential Crowdsourcing Applications in Urban Areas. *Big Data and Cognitive Computing*, 8(10). <https://doi.org/10.3390/bdcc8100126>
- Varadarajan, V., Garg, D., & Kotecha, K. (2021). An efficient deep convolutional neural network approach for object detection and recognition using a multi-scale anchor box in real-time. *Future Internet*, 13(12). <https://doi.org/10.3390/fi13120307>
- Villarini, G., Mandapaka, P. V., Krajewski, W. F., & Moore, R. J. (2008). Rainfall and sampling uncertainties: A rain gauge perspective. *Journal of Geophysical Research Atmospheres*, 113(11). <https://doi.org/10.1029/2007JD009214>

Referensi

- Wang, H., Xie, Q., Zhao, Q., & Meng, D. (2020). A Model-driven Deep Neural Network for Single Image Rain Removal.
- Wang, X., Wang, M., Liu, X., Zhu, L., Glade, T., Chen, M., Zhao, W., & Xie, Y. (2022). A novel quality control model of rainfall estimation with videos – A survey based on multi-surveillance cameras. *Journal of Hydrology*, 605, 127312. <https://doi.org/10.1016/J.JHYDROL.2021.127312>
- Wang, X., Wang, M., Liu, X., Zhu, L., Shi, S., Glade, T., Chen, M., Xie, Y., Wu, Y., & He, Y. (2023). Near-infrared surveillance video-based rain gauge. *Journal of Hydrology*, 618. <https://doi.org/10.1016/j.jhydrol.2023.129173>
- Zen, R., Arsa, D. M. S., Zhang, R., Er, N. A. S., & Bressan, S. (2019). Rainfall Estimation from Traffic Cameras. *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 11706 LNCS, 18–32. https://doi.org/10.1007/978-3-030-27615-7_2
- Zeng, Y., Yang, L., Tong, Z., Jiang, Y., Zhang, Z., Zhang, J., Zhou, Y., Li, J., Liu, F., & Liu, J. (2021). Statistical Characteristics of Raindrop Size Distribution during Rainy Seasons in Northwest China. *Advances in Meteorology*, 2021. <https://doi.org/10.1155/2021/6667786>
- Zheng, C., Jiang, J., Ying, W., & Wu, S. (2023). Single Image Deraining via Feature-based Deep Convolutional Neural Network. <http://arxiv.org/abs/2305.02100>
- Zheng, F., Yin, H., Ma, Y., Duan, H. F., Gupta, H., Savic, D., & Kapelan, Z. (2023). Toward Improved Real-Time Rainfall Intensity Estimation Using Video Surveillance Cameras. *Water Resources Research*, 59(8). <https://doi.org/10.1029/2023WR034831>
- Zheng, F., Yin, H., Zhang, J., Duan, H. F., & Gupta, H. V. (2024). A Bayesian deep learning approach for video-based estimation and uncertainty quantification of urban rainfall intensity. *Journal of Hydrology*, 640. <https://doi.org/10.1016/j.jhydrol.2024.131706>




UNIVERSITAS
INDONESIA

Terima Kasih

Additional Slide

Instrument Pengukuran Curah Hujan



Tipping Bucket (ARG)

$$R = \frac{V_b}{A}$$

R = Resolusi


V_b = Volume yang dapat dikumpulkan

A = Area Cawan ARG

$$i_{rec} = \frac{n \cdot R}{\Delta t}$$

n = Jumlah tuangan

Δt = Satuan waktu




Parsivel


$$V(D) = 9,6 - 10,3 \exp(-0,6D)$$

$$R = \frac{\pi}{6} \cdot 10^{-3} \cdot \sum_i N(D_i) \cdot D_i^3 \cdot V(D_i)$$

Instrument Pengukuran Curah Hujan




Gerbang MOS untuk silikon dengan doping P

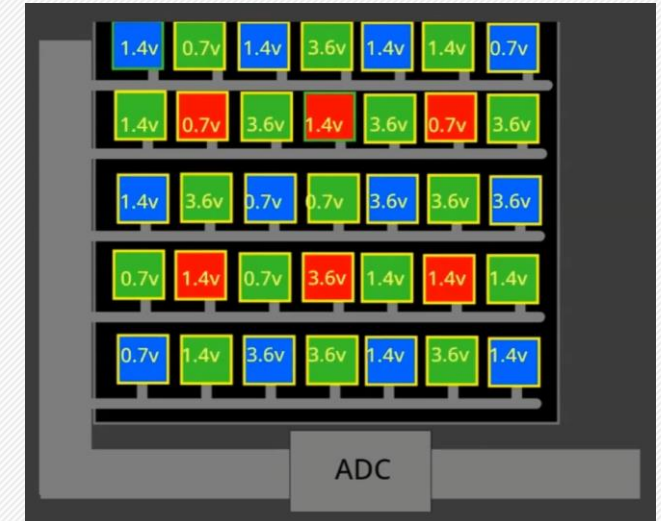



Block diagram sensor CMOS

Instrument Pengukuran Curah Hujan

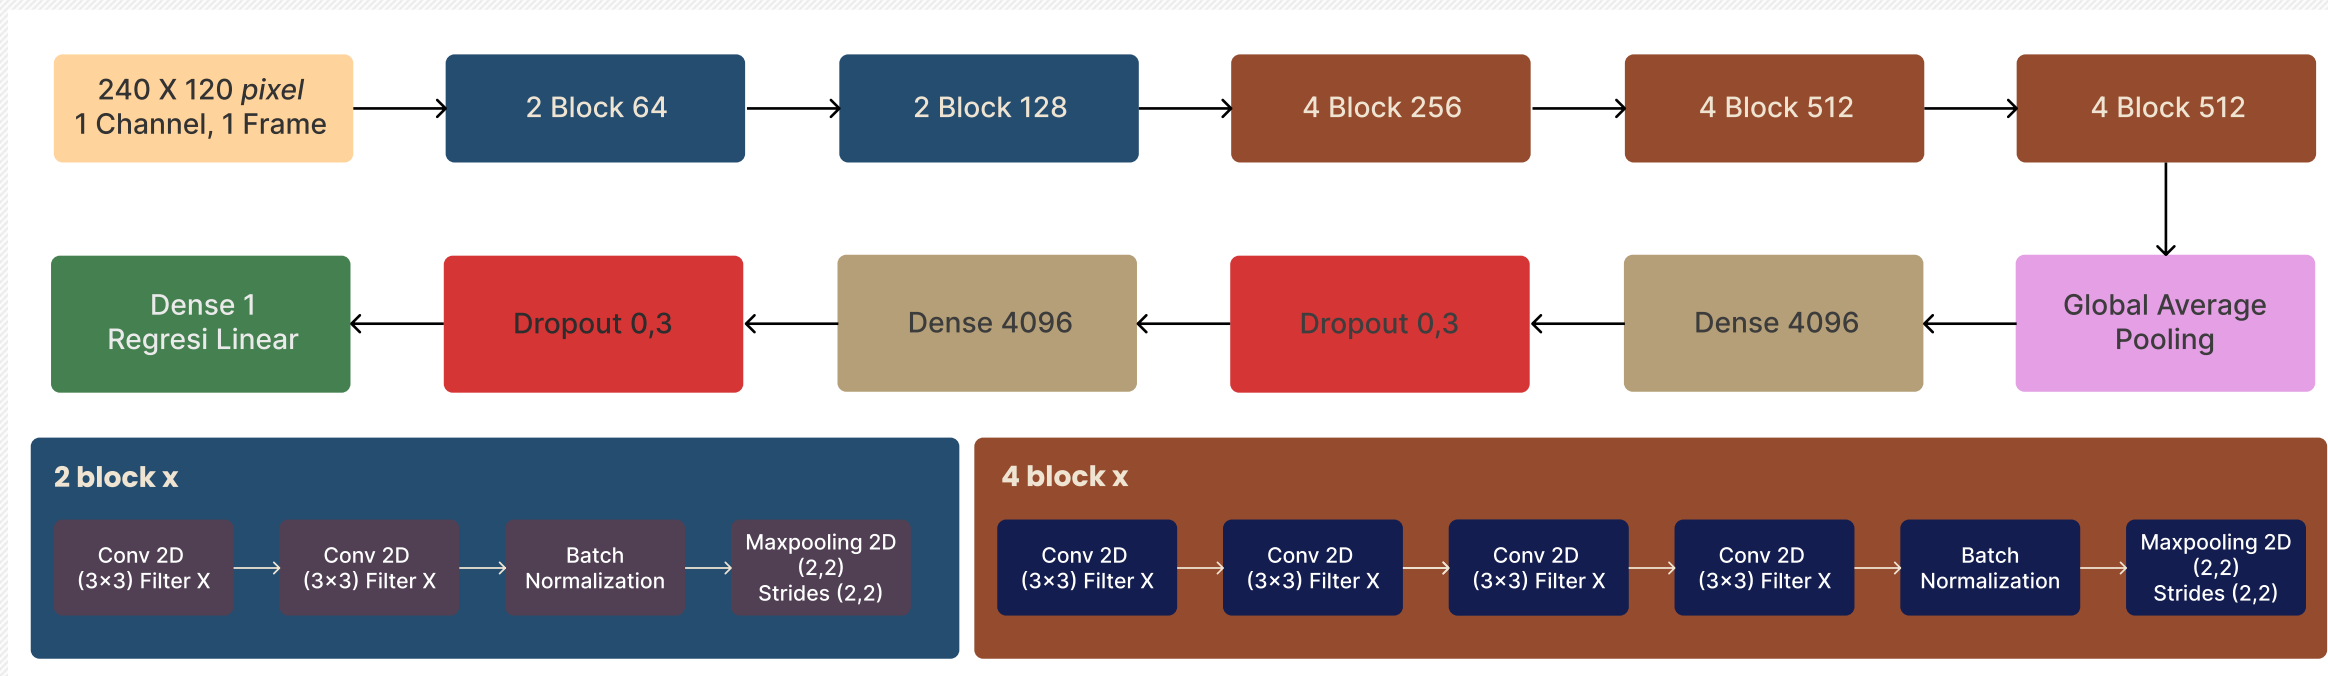


Hijau lebih banyak karena mata manusia lebih mudah melihat warna hijau




Rancangan & Metode Penelitian

Arsitektur Model CNN (VGG19)



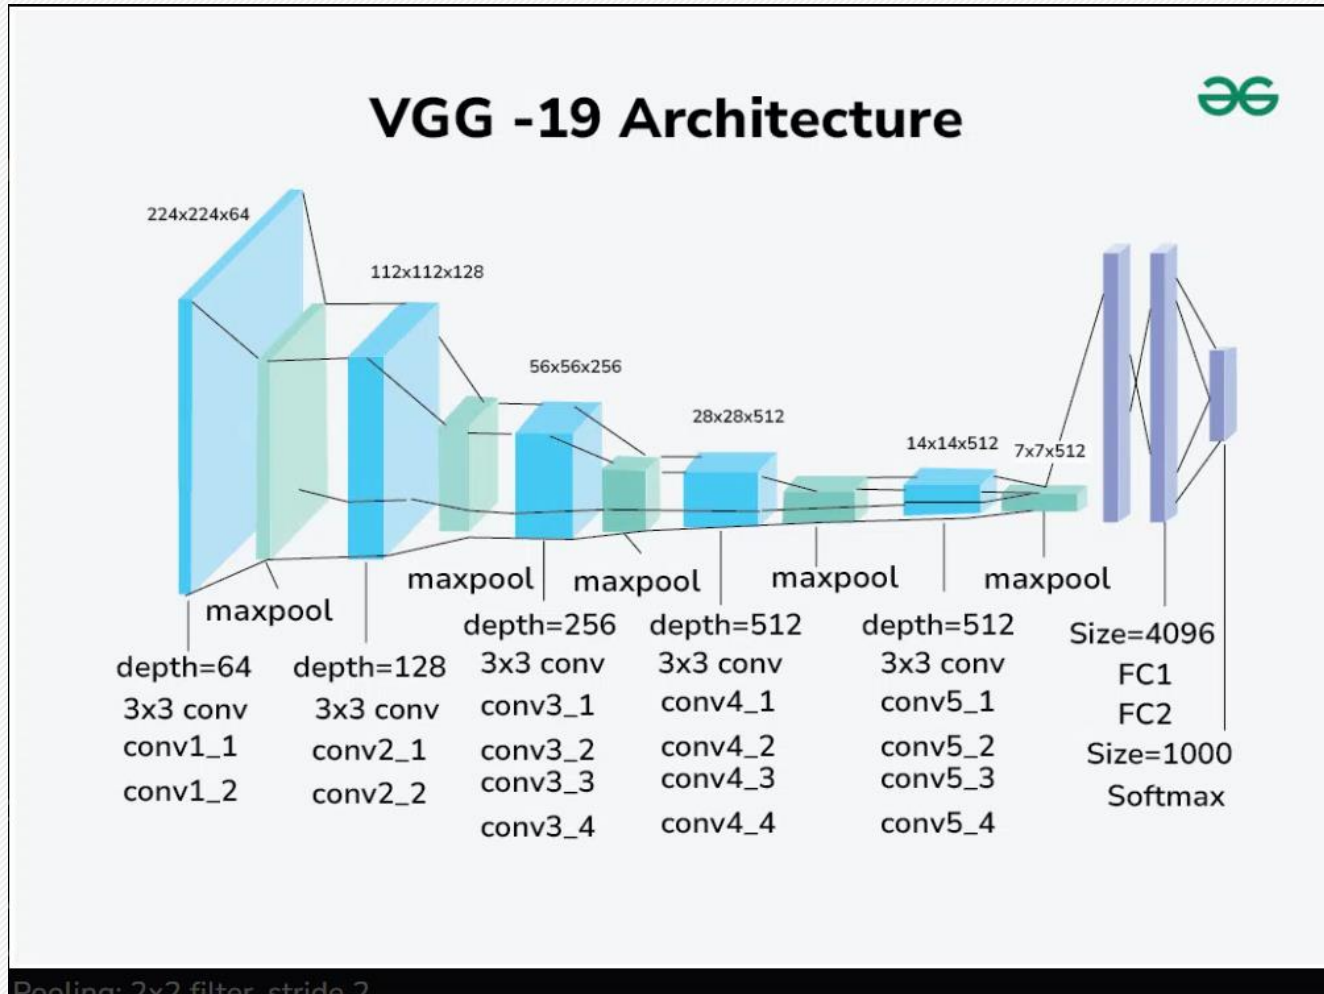
Rancangan & Metode Penelitian

LSTM



Rancangan & Metode Penelitian

CNN VGG



Model arsitektur dalam (19 layer: 16 Conv + 3 FC)
Dapat mempelajari fitur yang lebih kompleks

Robust dalam feature extraction

Convolution Layer

7	2	3	3	8
4	5	3	8	4
3	3	2	8	4
2	8	7	2	7
5	4	4	5	4

*

1	0	-1
1	0	-1
1	0	-1


=

6		

$$\begin{aligned}
 &7 \times 1 + 4 \times 1 + 3 \times 1 + \\
 &2 \times 0 + 5 \times 0 + 3 \times 0 + \\
 &3 \times -1 + 3 \times -1 + 2 \times -1 \\
 &= 6
 \end{aligned}$$

1 Fitur Map

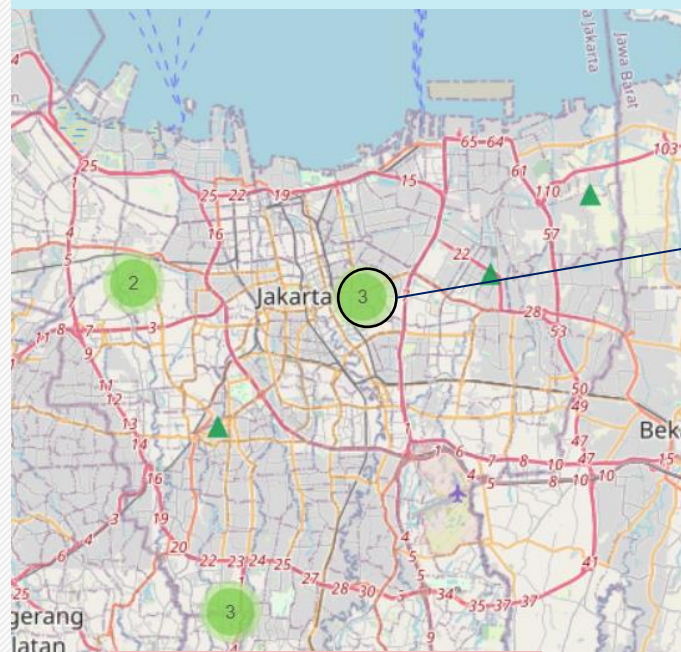
Convolution Layer



Pendahuluan

Latar Belakang Penelitian (2/3)

Persebaran ARG (Automatic Rain Gauge) di Jakarta



Hanya 11 di Jakarta

<https://awscenter.bmkg.go.id/>

Automatic Rain Gauge (ARG)



- + Dapat mengukur hujan lokal
- Hanya tersebar di beberapa titik
Tidak dapat mendeteksi hujan ringan (<0,2mm)
(Segovia-Cardozo et al., 2023)

Remote Sensing



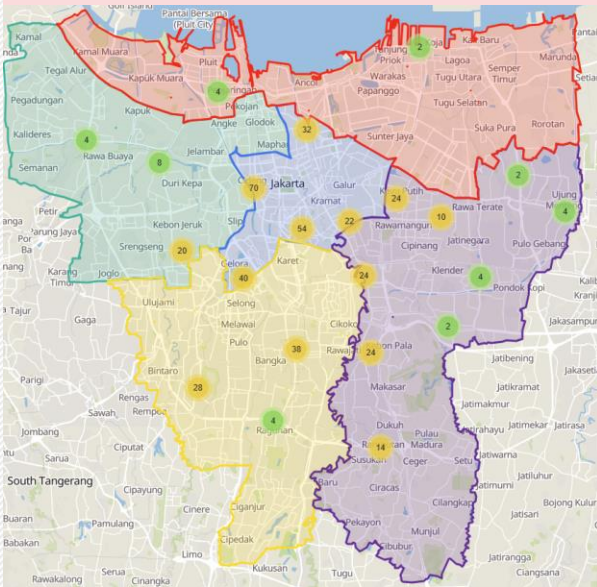
Sumber: <https://gpm.nasa.gov/data/visualizations/precip-apps>

- + Cakupannya luas
- Resolusi Spasial 10 km × 10km
Resolusi Temporal 30 menit
(F. Zheng et al., 2024)

Pendahuluan

Latar Belakang Penelitian (3/3)

Persebaran Kamera Pengawas ATCS
(Area Traffic Control System) di Jakarta




Sumber: <https://atcs-jakarta.com/Maps>

Kamera Pengawas



Citra



Model *Deep Learning* dengan
resolusi ***spatiotemporal*** tinggi

Banyak penelitian mengenai
pemanfaatan **kamera pengawas**
sebagai **sensor alternatif**
pengukuran curah hujan

(F. Zheng et al., 2023)

Jakarta memiliki 250+ Kamera
ATCS

Model yang ada pada
saat ini hanya fokus
pada satu **kondisi**
waktu

(Lee et al., 2023)

Banjir dapat terjadi
pada seluruh kondisi
waktu

(F. Zheng et al., 2023)